Dossiers do Portefólio — Investigação Empresarial

Oct 9, 2026 · @João Maria

Nota metodológica

Este documento reúne seis dossiers independentes (NVIDIA, Broadcom, LVMH, Microsoft, Meta Platforms, Netflix) e uma comparação final. A data de referência é 9 de outubro de 2026: os números são os últimos resultados anuais completos publicados até esta data, salvo indicação em contrário. A NVIDIA abre a série; os restantes dossiers estão em separadores próprios deste documento, pela ordem pedida.

Anos fiscais. Cada empresa fecha o ano numa data diferente, e misturá-las induz em erro. Convenções usadas:

Empresa	Fim do ano fiscal	Exemplo	Moeda
NVIDIA	Último domingo de janeiro	FY2026 = fev. 2025 – jan. 2026	USD
Broadcom	Domingo mais próximo de 31 de outubro	FY2025 = nov. 2024 – out. 2025	USD
LVMH	31 de dezembro	2025 = ano civil	EUR
Microsoft	30 de junho	FY2026 = jul. 2025 – jun. 2026	USD
Meta Platforms	31 de dezembro	2025 = ano civil	USD
Netflix	31 de dezembro	2025 = ano civil	USD

Grau de certeza. Ao longo do texto distingo quatro tipos de afirmação, sobretudo nas secções de estratégia e cenários:

- **Facto** — documentado em relatórios, documentos regulatórios ou fontes jornalísticas credíveis.
- **Gestão** — aquilo que a administração afirma ou promete; não é facto até se verificar.
- **Inferência** — conclusão analítica minha a partir dos factos.
- **Especulação** — hipótese plausível mas sem evidência suficiente.

Fontes. Prioridade a relatórios anuais (10-K, Document d'enregistrement universel), comunicados de resultados, cartas aos acionistas, entrevistas extensas com os responsáveis e jornalismo de referência. As ligações aparecem no texto e numa lista de fontes no fim de cada dossier. Quando uma história conhecida tem versões divergentes (frequente nas narrativas de fundação), a divergência é assinalada.

Limites. Não há conversas inventadas nem motivações atribuídas sem fonte. Os números financeiros vêm dos relatórios da empresa; estimativas de analistas, quando aparecem, são identificadas como tal. Isto não é aconselhamento de investimento: o objetivo é compreender os negócios, não recomendar compras ou vendas.

Índice da investigação

Cada dossier segue a mesma estrutura de 16 secções, para que as empresas possam ser comparadas ponto por ponto: 1. História · 2. Pessoas · 3. Pontos de viragem · 4. Sucessos e fracassos · 5. Modelo de negócio · 6. Produtos e tecnologia · 7. Aquisições e parcerias · 8. Concorrência e vantagem competitiva · 9. Cultura · 10. Evolução financeira · 11. Setor e contexto externo · 12. Riscos · 13. Presente e cenários · 14. Indicadores a acompanhar · 15. Lições · 16. Síntese e cronologia.

A estrutura é comum; as perguntas não. Abaixo, as questões centrais que cada dossier tenta responder.

Dossier 1 — NVIDIA

1. Como é que uma empresa de placas gráficas para videojogos, que esteve perto da falência em 1996–97, se tornou a infraestrutura central da inteligência artificial?
2. Porque é que a aposta no CUDA (2006), que durante quase uma década pareceu um desperdício de margem, foi a decisão mais importante da empresa?
3. O que vende realmente a NVIDIA hoje: chips, sistemas completos, redes ou software? E onde está o lucro?
4. Qual é a força real do seu "fosso" face à AMD, aos chips próprios da Google, Amazon e Microsoft, e aos chips chineses?
5. Quanto do sucesso recente é estrutural e quanto é um ciclo de investimento em centros de dados que pode abrandar?
6. Que dependências (TSMC, um punhado de clientes, Jensen Huang, geopolítica EUA–China) podem quebrar o modelo?

Dossier 2 — Broadcom

1. Como é que a Avago, uma antiga divisão da HP vendida a fundos de private equity, absorveu a Broadcom e se tornou um dos maiores grupos tecnológicos do mundo?

2. Qual é a lógica de Hock Tan: comprar negócios “franchise”, cortar o que não é essencial e extrair caixa? Funciona sempre?
3. Como é que a Broadcom se tornou parceira da Google, Meta e outros no desenho de chips de IA personalizados (ASIC), e porque isso a coloca tanto como concorrente como complemento da NVIDIA?
4. A aquisição da VMware (2023) criou valor ou apenas transferiu valor dos clientes através de aumentos de preço?
5. Quanto pesa a dívida e qual é a dependência de poucos clientes (Apple, Google)?

Dossier 3 — LVMH

1. Como é que Bernard Arnault, vindo da construção civil, assumiu o controlo da Boussac e depois da LVMH através de uma das batalhas empresariais mais duras da Europa?
2. O que torna a Louis Vuitton tão rentável, e porque é a moda e marroquinaria, e não os vinhos ou a distribuição, o coração dos lucros?
3. Como funciona o modelo de “casa de marcas”: autonomia criativa com controlo central de imobiliário, publicidade e distribuição?
4. Porque é o luxo menos imune aos ciclos do que parece, como mostrou o abrandamento pós-2023 na China e na “aspiração” da classe média?
5. O que acontece à governação e à estratégia quando Arnault sair, e como está a ser preparada a sucessão familiar?

Dossier 4 — Microsoft

1. Como passou a Microsoft do monopólio do Windows, do processo antitrust e da “década perdida” de Ballmer para a liderança na nuvem com Satya Nadella?
2. Porque é que a transição do Office vendido em caixa para a subscrição Microsoft 365 foi tão poderosa economicamente?
3. Como funciona o Azure e o que muda com a parceria com a OpenAI (investimento, exclusividade, renegociação de 2025)?
4. Que fracassos (Windows Phone, Nokia, Zune, aQuantive) ensinam sobre os limites de uma empresa dominante?
5. Será que o investimento maciço em centros de dados para IA vai gerar retornos comparáveis aos do passado?

Dossier 5 — Meta Platforms

1. Como passou o Facebook de um diretório universitário para uma máquina publicitária com mais de 3 mil milhões de utilizadores diários?

2. Porque foram as compras do Instagram (2012) e do WhatsApp (2014) provavelmente as aquisições mais rentáveis da história da tecnologia, e porque continuam sob escrutínio antitrust?
3. Como sobreviveu a empresa à transição para o telemóvel (2012) e ao golpe das regras de privacidade da Apple (2021–22)?
4. A aposta no metaverso (Reality Labs) é visão de longo prazo ou destruição de capital? E a aposta em IA e "superinteligência"?
5. O que significa o controlo absoluto de Zuckerberg (ações de classe B) para os acionistas?

Dossier 6 — Netflix

1. Como é que uma empresa de aluguer de DVD por correio sobreviveu à Blockbuster, depois canibalizou o próprio negócio para criar o streaming?
2. Porque foi a decisão de produzir conteúdo original (House of Cards, 2013) e de se expandir para 190 países tão arriscada e tão decisiva?
3. Como funciona a economia de um serviço de subscrição: custo do conteúdo amortizado, escala global, poder de preço?
4. O que mudou com a publicidade, o fim da partilha de contas e os eventos ao vivo?
5. Quem ganha as "guerras do streaming", e o YouTube é o verdadeiro concorrente?

Comparação final

1. Que lógicas económicas distintas estão neste portefólio (hardware cíclico, software recorrente, plataformas publicitárias, marcas de luxo, conteúdo por subscrição)?
2. Qual tem o fosso mais durável, a maior capacidade de subir preços, a menor intensidade de capital e a maior exposição à disrupção?
3. Onde estão as dependências cruzadas? (Microsoft e Meta são clientes da NVIDIA e da Broadcom; um abrandamento do investimento em IA afetaria quatro das seis empresas ao mesmo tempo.)
4. Que riscos se concentram no portefólio, e em que aspetos as empresas se equilibram umas às outras?

Dossier 1 — NVIDIA

Em resumo

A NVIDIA é hoje a principal fornecedora da infraestrutura de computação da inteligência artificial. No ano fiscal de 2026 (fevereiro de 2025 a janeiro de 2026) faturou 215,9 mil milhões de dólares, com 90% dessa receita vinda dos centros de dados e um lucro líquido

de 120,1 mil milhões (8-K FY2026). No segundo trimestre do ano fiscal de 2027 (maio a julho de 2026) a receita trimestral chegou aos 96,2 mil milhões, o dobro do mesmo período do ano anterior (comunicado Q2 FY2027).

O ponto central deste dossier é que este resultado não nasceu em 2023 com o ChatGPT. Resulta de uma sequência de apostas feitas ao longo de trinta anos: a GPU programável, o CUDA em 2006, a decisão de levar a sério a investigação académica em redes neuronais a partir de 2012, a compra da Mellanox em 2019 e a passagem de vender chips para vender sistemas completos. Muitas destas apostas pareceram más durante anos. Também há sorte: a IA moderna precisava exatamente do tipo de computação que a NVIDIA já vinha a construir por outras razões.

A tensão que atravessa todo o dossier: a NVIDIA tem uma posição competitiva excecional, mas a receita depende de um ciclo de investimento em centros de dados concentrado num pequeno número de clientes muito ricos, todos eles com incentivos fortes para reduzir essa dependência.

1. A história: do início até hoje

A história da NVIDIA divide-se em seis fases. Em cada uma, a empresa resolveu o problema da fase anterior e criou, quase sempre sem o saber, a base da seguinte.

Fase 1 (1993–1998): uma aposta nos videojogos 3D e uma quase-morte

O contexto. No início dos anos 90 o PC estava a tornar-se um produto de massas, mas os gráficos eram pobres. O processador central (CPU) fazia quase tudo, e calcular imagens tridimensionais em tempo real exige repetir a mesma operação matemática sobre milhões de pontos e píxeis. Para isso um CPU, desenhado para executar instruções variadas uma de cada vez, é ineficiente. Havia dezenas de pequenas empresas a tentar construir chips aceleradores de gráficos; a maioria desapareceu.

Os fundadores. A NVIDIA foi fundada a 5 de abril de 1993 por Jensen Huang, Chris Malachowsky e Curtis Priem (cronologia oficial). Huang, então com 30 anos, era engenheiro e diretor na LSI Logic, depois de ter passado pela AMD. Malachowsky e Priem eram engenheiros de gráficos na Sun Microsystems e estavam frustrados com a falta de apoio interno aos seus projetos. As reuniões iniciais decorreram num restaurante Denny's em San Jose, um detalhe que a empresa transformou em mito fundador.

A tese original. A ideia era que a computação acelerada, ou seja, chips especializados para tarefas que o CPU faz mal, viria a ser essencial, e que os videojogos 3D seriam o primeiro mercado grande o suficiente para a financiar. Os videojogos eram então vistos como um nicho pouco sério; para os fundadores eram um mercado com procura insaciável por mais desempenho, o que garantia um ciclo de renovação constante.

Recursos iniciais. A empresa obteve financiamento de capital de risco da Sequoia Capital (Don Valentine) e da Sutter Hill Ventures, cerca de 20 milhões de dólares segundo os relatos mais citados. Huang conta que a recomendação de Wilf Corrigan, fundador da LSI Logic, pesou na decisão da Sequoia.

O primeiro produto e o primeiro fracasso. O NV1 chegou ao mercado em 1995, vendido sobretudo na placa Diamond Edge 3D. Era um chip ambicioso, que combinava gráficos, som e controlo de jogo, e desenhava imagens com superfícies curvas (texturas quadráticas) em vez de triângulos. Foi uma escolha técnica errada no momento errado: a Microsoft lançou o DirectX, que padronizou os gráficos de PC em torno de triângulos, e os programadores de jogos seguiram o padrão. O NV1 ficou isolado.

O episódio Sega. A NVIDIA tinha também um contrato com a Sega para desenvolver o chip gráfico de uma consola futura, baseado na mesma arquitetura. Huang concluiu que a arquitetura não tinha futuro e contou, no discurso de 2023 na Universidade Nacional de Taiwan, que contactou o presidente da Sega para admitir o erro, desistir do contrato e, ainda assim, pedir que a Sega pagasse, porque sem esse dinheiro a NVIDIA fecharia (blog NVIDIA sobre o discurso). Segundo os relatos posteriores, o executivo da Sega, Shoichiro Irimajiri, aceitou converter os últimos 5 milhões de dólares do contrato num investimento em capital (The Next Web). As fontes divergem quanto ao ano (1995 ou 1996). Huang diz que isso deu à empresa "seis meses de vida". A NVIDIA despediu mais de metade dos cerca de cem trabalhadores.

A salvação: RIVA 128 (1997). Com os seis meses que restavam, a equipa desenhou um chip compatível com o DirectX, o RIVA 128. Para ganhar tempo, a NVIDIA comprou um emulador de hardware, uma máquina que simula o chip antes de ele ser fabricado, e enviou o desenho diretamente para produção sem fazer as habituais iterações com protótipos físicos. Era uma aposta: um erro no silício teria sido fatal. O RIVA 128 funcionou e vendeu cerca de um milhão de unidades nos primeiros meses, segundo os relatos de Huang e a biografia da empresa escrita por Tae Kim (*The Nvidia Way*, 2024). Desta fase vem o lema interno "estamos a trinta dias de falir", que Huang repetiu durante anos.

O que mudou nesta fase. A NVIDIA aprendeu duas lições que moldaram a cultura: seguir os padrões do ecossistema em vez de os combater sozinha, e ser mais rápida do que todos os concorrentes. Decidiu lançar uma nova geração de chips a cada seis meses, ritmo que a maioria dos rivais não conseguiu acompanhar.

Fase 2 (1999–2005): a GPU, a bolsa e a vitória na guerra gráfica

Em janeiro de 1999 a NVIDIA entrou em bolsa (Nasdaq) a 12 dólares por ação. Em agosto desse ano anunciou a GeForce 256, que apresentou como "a primeira GPU do mundo" (graphics processing unit). A designação era em parte marketing, mas havia uma inovação

real: o chip passou a fazer a transformação e iluminação da geometria, trabalho que antes cabia ao CPU. A GPU deixava de ser um acessório de desenho e passava a ser um processador.

O mercado consolidou-se depressa. A 3dfx, líder em 1997–98 com as placas Voodoo, cometeu dois erros: decidiu fabricar as suas próprias placas (afastando os parceiros que as montavam) e atrasou-se nas gerações seguintes. Em dezembro de 2000 a NVIDIA comprou os ativos e as patentes da 3dfx por cerca de 70 milhões de dólares em dinheiro mais ações. No mesmo período ganhou o contrato do chip gráfico da primeira Xbox da Microsoft (2001), que lhe deu escala e prestígio, embora as negociações de preço com a Microsoft tenham acabado em arbitragem.

A vitória não foi linear. Em 2002–03 a ATI (mais tarde comprada pela AMD) lançou a Radeon 9700, superior à GeForce FX (NV30) da NVIDIA, que chegou atrasada, quente e ruidosa. A NVIDIA perdeu quota durante cerca de dois anos e recuperou com as gerações seguintes. O mercado de placas gráficas dedicadas ficou reduzido a dois concorrentes, NVIDIA e ATI/AMD, situação que se mantém.

Fase 3 (2006–2012): a aposta no CUDA e os anos difíceis

A ideia. A partir de 2001 as GPU passaram a ter partes programáveis (“shaders”), para que os programadores de jogos pudessem criar efeitos visuais próprios. Investigadores universitários perceberam que esse poder de cálculo paralelo podia servir para ciência, disfarçando problemas matemáticos como se fossem imagens. Um deles, Ian Buck, criou em Stanford a linguagem Brook e foi contratado pela NVIDIA em 2004.

A decisão. Em novembro de 2006 a NVIDIA lançou a GeForce 8800 (arquitetura G80) e o CUDA, uma plataforma que permitia programar a GPU em linguagem C para qualquer tarefa de cálculo, não apenas gráficos. A parte mais arriscada não foi o software em si, mas a decisão de colocar capacidade CUDA em todas as GPU vendidas, incluindo as placas de jogos baratas. Isso aumentava o tamanho e o custo de cada chip numa altura em que a esmagadora maioria dos clientes não queria nem sabia o que era computação geral na GPU. O ponto de viragem 3.2 analisa esta decisão em detalhe.

Os anos maus. O CUDA demorou quase uma década a ter retorno significativo, e entretanto a empresa atravessou várias crises em simultâneo:

- **2008: defeitos e crise financeira.** A NVIDIA registou um encargo de cerca de 200 milhões de dólares por chips para portáteis com taxas de falha anormais (o caso ficou conhecido como “bumpgate”). Com a crise financeira, a ação caiu mais de 80% entre o máximo de 2007 e o final de 2008.
- **O conflito com a Intel.** A NVIDIA fabricava chipsets para placas-mãe de PCs com processadores Intel. A Intel contestou a licença para as novas gerações e integrou os gráficos nos seus próprios processadores, eliminando esse negócio. O litígio terminou

em 2011 com um acordo em que a Intel pagou 1,5 mil milhões de dólares em licenças ao longo de seis anos.

- **O falhanço no telemóvel.** Com os processadores Tegra (a partir de 2008) e a compra da Icera (2011, modems), a NVIDIA tentou entrar nos smartphones. Perdeu para a Qualcomm, que integrava o modem no mesmo chip, e para a Apple e a Samsung, que desenharam os seus próprios processadores. A NVIDIA abandonou os telemóveis por volta de 2014. O Tegra sobreviveu na Nintendo Switch (2017) e no automóvel.

Durante estes anos, Huang manteve o investimento no CUDA apesar da pressão de acionistas para melhorar margens. A empresa financiou cursos universitários, ofereceu hardware a investigadores e construiu bibliotecas de software para áreas como física, finanças e imagem médica. Em 2008 lançou a linha Tesla para supercomputadores, que deu um primeiro mercado profissional ao CUDA.

Fase 4 (2012–2019): a inteligência artificial descobre a GPU

Em 2012 Alex Krizhevsky, Ilya Sutskever e Geoffrey Hinton, da Universidade de Toronto, venceram o concurso de reconhecimento de imagem ImageNet com uma rede neuronal, a AlexNet, treinada em duas placas gráficas GeForce GTX 580 de consumo. A margem de vitória foi tal que a comunidade de visão por computador mudou de método em poucos anos. A razão técnica é simples: treinar redes neuronais consiste sobretudo em multiplicar matrizes enormes, precisamente o cálculo paralelo em que as GPU são boas, e o CUDA tornava isso acessível a um estudante de doutoramento.

A NVIDIA não previu a AlexNet, mas reagiu depressa. Criou bibliotecas específicas para redes neuronais (cuDNN, 2014), reorientou o desenho dos chips e, em 2016, lançou o DGX-1, um servidor dedicado à IA. Huang entregou pessoalmente o primeiro DGX-1 à OpenAI, então uma pequena organização sem fins lucrativos, em agosto de 2016. Em 2017 a arquitetura Volta (V100) introduziu os Tensor Cores, circuitos especializados em multiplicação de matrizes: a GPU começava a ser desenhada para a IA, não apenas adaptada a ela.

O negócio de centros de dados cresceu de cerca de 0,3 mil milhões de dólares (ano fiscal de 2016) para quase 3 mil milhões (ano fiscal de 2020). Mas os jogos continuavam a ser a maior fonte de receita, e esta fase teve também um episódio que mostra os riscos da ciclicidade: em 2017–18 a mineração de criptomoedas fez disparar a procura de placas gráficas, e o colapso das criptomoedas no final de 2018 deixou excesso de stock nos canais de venda. A receita caiu 7% no ano fiscal de 2020. Em 2022 a SEC multou a NVIDIA em 5,5 milhões de dólares por não ter divulgado adequadamente quanto das vendas de jogos dependia da mineração.

Fase 5 (2019–2022): de fabricante de chips a plataforma de centro de dados

Nesta fase a NVIDIA percebeu que a unidade de computação relevante para a IA já não era o chip, mas o centro de dados inteiro: milhares de GPU que têm de trocar dados entre si a velocidades enormes. Daqui resultaram três decisões:

1. **Mellanox (anunciada em março de 2019, concluída em abril de 2020, 6,9 mil milhões de dólares).** A empresa israelita era líder em InfiniBand, a tecnologia de rede usada nos supercomputadores. Deu à NVIDIA a capacidade de vender a rede que liga as GPU.
2. **A tentativa de comprar a Arm (setembro de 2020, 40 mil milhões de dólares).** Teria dado à NVIDIA a arquitetura de processadores usada em quase todos os telemóveis. Reguladores nos EUA, Reino Unido, UE e China opuseram-se, e o negócio foi abandonado em fevereiro de 2022, com um encargo de cerca de 1,4 mil milhões. A NVIDIA acabou por desenhar o seu próprio CPU baseado em Arm (Grace) com uma licença normal.
3. **Sistemas completos.** Com a A100 (2020) e a H100 (2022), a NVIDIA passou a vender cada vez mais placas com oito GPU interligadas (HGX), servidores DGX e projetos de referência para clusters inteiros.

No ano fiscal de 2021 (fevereiro de 2020 a janeiro de 2021) a pandemia acelerou jogos e centros de dados. Em 2022 o ciclo inverteu-se: queda do consumo de PCs, segundo colapso das criptomoedas, excesso de stock e as primeiras restrições dos EUA à exportação de chips avançados para a China (outubro de 2022). A receita do ano fiscal de 2023 ficou estagnada (+0,2%) e o lucro líquido caiu 55%. A ação perdeu cerca de dois terços do valor entre novembro de 2021 e outubro de 2022.

Fase 6 (2023–hoje): a explosão da IA generativa

O ChatGPT foi lançado a 30 de novembro de 2022. Em poucos meses, todas as grandes empresas tecnológicas decidiram que precisavam de treinar e servir modelos de linguagem de grande dimensão, e havia um único fornecedor capaz de entregar a pilha completa de hardware e software: a NVIDIA. Em maio de 2023 a empresa anunciou uma previsão de receita para o trimestre seguinte de 11 mil milhões de dólares, cerca de 50% acima do que os analistas esperavam, num dos maiores choques positivos de previsão da história das grandes empresas cotadas.

A partir daí, o crescimento foi de uma escala sem precedentes para uma empresa desta dimensão: a receita passou de 27,0 mil milhões (ano fiscal de 2023) para 60,9, 130,5 e 215,9 mil milhões nos três anos seguintes. A capitalização bolsista ultrapassou um bilião de dólares (trillion) em maio de 2023, e os cinco biliões no final de outubro de 2025.

Esta fase trouxe também mudanças na forma como a empresa funciona:

- **Cadência anual.** Desde 2024 a NVIDIA lança uma arquitetura de centro de dados por ano (Hopper, Blackwell, Blackwell Ultra, Rubin), em vez de a cada dois anos.
- **Sistemas à escala do bastidor.** O GB200 NVL72 (2024–25) liga 72 GPU num só bastidor (rack) que funciona como um único computador gigante. A NVIDIA passou a desenhar o bastidor inteiro, da refrigeração líquida aos cabos.
- **Investimento no ecossistema.** A NVIDIA passou a investir diretamente nos seus clientes e parceiros: 5 mil milhões na Intel (2025), um investimento de 30 mil milhões na OpenAI em 2026 (depois de uma carta de intenções de até 100 mil milhões nunca concretizada), uma parceria e investimento na Anthropic, e um acordo de licenciamento de tecnologia com a Groq, avaliado pela imprensa em cerca de 20 mil milhões (dezembro de 2025).
- **Geopolítica.** As vendas de chips de centro de dados para a China, que chegaram a representar mais de 20% da receita, foram progressivamente restringidas. As previsões de 2026 já não incluem qualquer receita de computação para centros de dados na China.
- **Nova segmentação.** A partir do ano fiscal de 2027 a NVIDIA passou a reportar apenas dois segmentos: Data Center (subdividido em “Hyperscale” e “AI Clouds, Industrial and Enterprise”) e Edge Computing, que agrega jogos, visualização profissional, automóvel e robótica (Global Data Center Hub). A mudança é simbólica: os jogos, que deram origem à empresa, deixaram de ser um segmento autonomamente reportado.

A lógica que liga as fases. Os jogos financiaram o desenvolvimento da GPU; a GPU programável tornou o CUDA possível; o CUDA criou uma comunidade de investigadores que, por acaso e por insistência, descobriu que as redes neuronais funcionavam nas GPU; o sucesso na IA levou a NVIDIA a desenhar centros de dados inteiros. Cada fase foi paga pela anterior. Sem o negócio de jogos, a NVIDIA não teria tido a escala de produção nem o volume de vendas para distribuir o CUDA por centenas de milhões de computadores.

2. As pessoas mais importantes

A NVIDIA é invulgar entre as grandes tecnológicas: o fundador que a criou em 1993 continua a dirigi-la 33 anos depois, e a equipa de topo é extraordinariamente estável. Isso torna fácil atribuir tudo a Jensen Huang, e seria um erro. A visão estratégica é dele, mas o CUDA foi construído por engenheiros específicos, a viragem para a IA foi descoberta por académicos de fora, e a capacidade de entregar centenas de milhares de sistemas por trimestre depende de uma organização de operações e de um parceiro, a TSMC, que a NVIDIA não controla.

Jensen Huang — cofundador, presidente executivo desde 1993

Percurso. Nasceu em 1963 em Tainãn, Taiwan. Foi enviado para os EUA aos nove anos e estudou num colégio interno no Kentucky. Licenciou-se em engenharia elétrica na Oregon State University (1984) e fez o mestrado em Stanford (1992), em regime pós-laboral. Trabalhou como desenhador de microprocessadores na AMD e depois na LSI Logic, onde chegou a diretor de uma divisão. A LSI ensinou-lhe o lado comercial dos semicondutores: como se vende um chip a um fabricante de computadores.

O que o distingue. Três traços aparecem consistentemente nas biografias e entrevistas. Primeiro, raciocina a partir de primeiros princípios sobre onde a computação vai estar daqui a dez anos, e está disposto a sacrificar margem atual por essa visão. Segundo, combina essa visão com um domínio técnico e operacional raro num CEO desta dimensão: conhece os detalhes dos produtos. Terceiro, gere de forma muito pouco convencional, com dezenas de subordinados diretos, sem reuniões individuais regulares e com críticas feitas em público para que toda a organização aprenda (ver secção 9).

Decisões concretas. Abandonar a arquitetura do NV1 e o contrato da Sega (1996); apostar o que restava do dinheiro no RIVA 128 sem protótipo físico (1997); pôr o CUDA em todas as GPU (2006) e manter o investimento durante anos de margens comprimidas; reorientar a empresa para a IA a partir de 2013–14, quando o negócio era ainda minúsculo; comprar a Mellanox (2019); passar para uma cadência anual de arquiteturas e para sistemas completos (2024); usar o balanço para investir em clientes e parceiros (2025–26).

Erros e controvérsias. A arquitetura do NV1 foi um erro técnico grave. A incursão nos telemóveis (Tegra, Icera) consumiu anos e centenas de milhões sem resultado. A tentativa de comprar a Arm subestimou a oposição regulatória e da indústria. A gestão da exposição às criptomoedas em 2017–18 resultou numa multa da SEC. Mais recentemente, o anúncio de um investimento de até 100 mil milhões na OpenAI (setembro de 2025), depois reduzido a 30 mil milhões, alimentou críticas de que a NVIDIA estaria a financiar a procura pelos seus próprios produtos (“financiamento circular”, ver secção 12).

Legado. Huang transformou uma empresa de placas para jogos na empresa de semicondutores mais valiosa do mundo, sobretudo pela paciência estratégica: o CUDA levou cerca de dez anos a pagar-se. O lado negativo do legado é a dependência: a cultura, a rede de relações com clientes e a seleção de apostas estão muito centradas numa pessoa com 63 anos e sem sucessor publicamente identificado.

Chris Malachowsky — cofundador, engenharia e operações

Engenheiro elétrico (Universidade da Florida, mestrado em Santa Clara), trabalhou na HP e na Sun Microsystems, onde foi um dos autores dos sistemas gráficos das estações de trabalho. Na NVIDIA dirigiu durante anos a engenharia de hardware e as operações, construindo o processo de verificação e produção que permitiu a cadência rápida de

lançamentos. Continua na empresa como NVIDIA Fellow. É o caso típico do fundador que executa: menos visível, mas essencial para que a visão de Huang se traduzisse em chips que funcionavam à primeira.

Curtis Priem — cofundador, primeiro diretor técnico

Arquiteto de gráficos na IBM, Vermont Microsystems e Sun, onde desenhou o acelerador GX. Foi o principal arquiteto do NV1 e de vários chips seguintes, e responsável por muitas das primeiras patentes da empresa. Saiu em 2003. O NV1, a sua obra principal, foi um fracasso comercial; mas o trabalho de arquitetura e de interfaces que liderou (incluindo a abordagem a controladores de software) foi base dos produtos seguintes. Vendeu a maior parte das ações cedo e dedicou-se à filantropia.

Os investidores iniciais: Don Valentine, Mark Stevens e Tench Coxe

Don Valentine, fundador da Sequoia, investiu em 1993 com base na reputação de Huang. Mark Stevens (Sequoia) e Tench Coxe (Sutter Hill) integraram o conselho de administração e mantiveram-se durante décadas. A importância deles não está apenas no capital inicial: um conselho estável e alinhado com o fundador deu a Huang margem para manter o CUDA durante anos em que o mercado bolsista punia a empresa. O reverso é a crítica, frequente entre especialistas em governação, de que um conselho com membros de mandato tão longo tem pouca independência face ao CEO.

Os construtores do CUDA: Ian Buck, John Nickolls e David Kirk

- **David Kirk**, diretor científico de 1997 a 2009, defendeu internamente a computação geral na GPU e ajudou a levá-la para as universidades, incluindo um dos primeiros cursos e manuais sobre programação paralela, escrito com Wen-mei Hwu (Universidade de Illinois).
- **Ian Buck** criou em Stanford a linguagem Brook, que mostrou que as GPU podiam ser programadas para cálculo científico. Contratado em 2004, liderou o desenvolvimento do CUDA. Hoje dirige a área de computação para hiperescala e supercomputação.
- **John Nickolls** liderou a arquitetura de hardware e software do CUDA até à sua morte, em 2011.

O CUDA é talvez o melhor exemplo de que o sucesso da NVIDIA não é obra de uma pessoa: a ideia veio do meio académico, foi transformada em produto por uma pequena equipa e só sobreviveu porque a direção a financiou durante anos.

Bill Dally — diretor científico desde 2009

Professor e diretor do departamento de informática de Stanford, especialista em arquiteturas paralelas e redes de interligação. Na NVIDIA reorganizou a investigação e foi central para várias inovações que deram vantagem na IA: cálculo em precisão reduzida (usar números com menos bits, o que multiplica o desempenho em redes neuronais sem perda relevante de qualidade), as interligações NVLink entre GPU e a investigação em aceleradores especializados. Representa a ponte entre a investigação de ponta e o produto.

Bryan Catanzaro — a ponte para o deep learning

Investigador da NVIDIA que, em 2013, colaborou com Andrew Ng e a equipa de Stanford num trabalho que mostrou que poucos servidores com GPU podiam igualar o que a Google tinha feito com milhares de CPU. Liderou o desenvolvimento da cuDNN (2014), a biblioteca de primitivas para redes neuronais que se tornou a base sobre a qual frameworks como o TensorFlow e o PyTorch correm nas GPU. Hoje lidera a investigação aplicada em deep learning.

Jonah Alben — arquitetura de GPU

Vice-presidente sénior de engenharia de GPU, na empresa desde 1997, responsável pela arquitetura de várias gerações. É um dos nomes menos conhecidos fora da indústria e mais importantes dentro dela: a capacidade de entregar uma arquitetura nova por ano depende desta equipa.

Colette Kress — diretora financeira desde 2013

Veio da Cisco e, antes, da Microsoft. Gere a relação com os investidores, a afetação de capital (recompras de ações de 40 mil milhões no ano fiscal de 2026) e, cada vez mais, compromissos de compra a fornecedores de dimensão enorme. A disciplina na comunicação de previsões, que a NVIDIA tem batido consistentemente, é em parte obra sua.

Debora Shoquist e Jay Puri — operações e vendas

Shoquist (vice-presidente executiva de operações) gere a cadeia de abastecimento: a capacidade reservada na TSMC, o empacotamento avançado CoWoS e a memória HBM, que nos últimos anos foram o verdadeiro limite às vendas. Puri (vice-presidente executivo de operações de campo) gere as relações comerciais globais com fabricantes de servidores, fornecedores de nuvem e governos. Numa fase em que a procura excede a oferta, quem decide a afetação de produto tem enorme poder.

Os homens da Mellanox: Eyal Waldman e Michael Kagan

Waldman fundou a Mellanox em 1999 e saiu após a aquisição. Kagan, cofundador, tornou-se diretor tecnológico da NVIDIA. A equipa israelita trouxe a competência em redes que permitiu à NVIDIA vender clusters inteiros; a divisão de redes gerou cerca de 14,8 mil milhões de dólares só no primeiro trimestre do ano fiscal de 2027, segundo as análises do relatório trimestral.

Figuras externas determinantes

- **Morris Chang e a TSMC.** Todos os chips avançados da NVIDIA são fabricados pela TSMC. Huang descreve a relação como uma das mais importantes da empresa desde os anos 90. A NVIDIA nunca teve fábricas, o que lhe poupou capital mas a deixou dependente de um único fornecedor localizado em Taiwan.
- **Geoffrey Hinton, Alex Krizhevsky e Ilya Sutskever.** A AlexNet (2012) demonstrou ao mundo o que as GPU podiam fazer pela IA. Não trabalhavam para a NVIDIA.
- **Shoichiro Irimajiri (Sega).** O investimento de 5 milhões em meados dos anos 90 foi, nas palavras de Huang, o que manteve a empresa viva.

Visão versus execução

Papel	Pessoas	Contributo
Criaram a visão original	Huang, Malachowsky, Priem	Computação acelerada, com os jogos como primeiro mercado
Transformaram a visão	Huang, Kirk, Buck, Nickolls	GPU como processador geral (CUDA)
Descobriram a aplicação decisiva	Hinton, Krizhevsky, Sutskever, Ng, Catanzaro	Deep learning em GPU
Escalaram	Dally, Alben, Shoquist, Puri, Kress, Kagan	Arquitetura anual, cadeia de abastecimento, redes, finanças

3. Os pontos de viragem

Nove momentos explicam a trajetória da NVIDIA. Para cada um: (A) contexto, (B) problema ou oportunidade, (C) decisão e alternativas, (D) risco, (E) execução, (F) resultado, (G) impacto duradouro, (H) lição para o investidor.

3.1 Sobreviver ao NV1: o RIVA 128 (1996–1997)

A. Contexto. O NV1 tinha falhado e o DirectX da Microsoft impunha os triângulos como padrão. Havia mais de trinta concorrentes em chips gráficos e a 3dfx dominava o mercado de jogos.

B. Problema. A empresa tinha dinheiro para poucos meses e uma arquitetura sem futuro.

C. Decisão. Abandonar a arquitetura proprietária, seguir o padrão da Microsoft e construir o chip mais rápido possível compatível com ele. As alternativas eram vender a empresa, procurar um nicho para a tecnologia do NV1 ou tentar mais uma ronda de capital numa altura em que a empresa tinha um fracasso no currículo.

D. Risco. Para chegar a tempo, o chip foi validado num emulador e enviado para produção sem protótipos físicos intermediários. Um erro de desenho significaria o fim da empresa.

E. Execução. Uma equipa reduzida a cerca de quarenta pessoas, um emulador comprado com uma parte importante do dinheiro restante, e a TSMC como fábrica.

F. Resultado. O RIVA 128 (1997) vendeu cerca de um milhão de unidades em poucos meses e deu à NVIDIA uma posição entre os líderes.

G. Impacto duradouro. Daqui nasceram três pilares: o uso intensivo de simulação para desenhar chips mais depressa do que os rivais; uma cadência de lançamentos agressiva; e uma cultura de urgência permanente.

H. Lição. Uma empresa que sobrevive a um erro grave aprende algo que os concorrentes sem esse trauma não aprendem. Mas a sobrevivência também dependeu de sorte (a generosidade da Sega). O investidor não deve confundir resultado com inevitabilidade.

3.2 O CUDA: transformar a GPU num computador geral (2006)

A. Contexto. Em 2006 a NVIDIA era uma empresa de gráficos rentável, a AMD acabava de comprar a ATI, e a Intel preparava-se para integrar gráficos nos seus processadores. Investigadores já usavam GPU para cálculo científico, mas de forma artesanal.

B. Oportunidade. Se a GPU pudesse ser programada facilmente para qualquer cálculo paralelo, a NVIDIA deixaria de depender só dos jogos e entraria na computação científica e empresarial.

C. Decisão. Lançar o CUDA com a arquitetura G80 e colocá-lo em todas as GPU, incluindo as de consumo. A alternativa mais prudente teria sido uma linha separada de chips para cálculo científico, mais barata de manter mas com uma base instalada minúscula. Huang escolheu a opção cara porque uma plataforma de software só atrai programadores se estiver em todo o lado.

D. Risco. Os circuitos adicionais aumentavam o custo de cada chip, comprimindo margens num mercado de jogos muito competitivo. Durante anos não houve uma aplicação "assassina". Huang referiu no discurso de 2023 que o CUDA quase levou a empresa a perder o seu valor de mercado; a ação passou anos abaixo do máximo de 2007.

E. Execução. Não bastava um compilador. A NVIDIA investiu em bibliotecas matemáticas (cuBLAS, cuFFT), ferramentas, documentação, cursos universitários, doações de hardware e conferências próprias (GTC, a partir de 2009). Foi um investimento em comunidade tanto quanto em tecnologia.

F. Resultado. Durante cerca de seis anos, o CUDA teve impacto comercial modesto (supercomputadores, finanças, petróleo e gás). Depois, a partir de 2012, tornou-se a linguagem em que o deep learning foi escrito.

G. Impacto duradouro. O CUDA é a principal razão pela qual os concorrentes com hardware competitivo têm dificuldade em ganhar clientes: milhões de programadores, milhares de bibliotecas e quase duas décadas de otimizações foram construídos sobre ele (ver secção 8).

H. Lição. As vantagens competitivas mais duráveis são muitas vezes construídas em períodos em que parecem destruir valor. Na altura, não era evidente que o CUDA viria a valer alguma coisa; a aposta era em computação paralela em geral, não em IA especificamente. O sucesso foi uma combinação de visão, persistência e sorte na aplicação que acabou por surgir.

3.3 A AlexNet e a reorientação para a IA (2012–2016)

A. Contexto. A NVIDIA vinha de anos difíceis (Tegra, Intel, crise de 2008). O mercado de PCs estava a estagnar com a ascensão dos telemóveis.

B. Oportunidade. A AlexNet mostrou que redes neuronais treinadas em GPU superavam todos os métodos anteriores em visão por computador. Pouco depois, resultados semelhantes surgiram em reconhecimento de voz e tradução.

C. Decisão. Segundo os relatos de Huang e de executivos, a partir de 2013–14 a empresa decidiu tratar o deep learning como a próxima grande plataforma e reorientar investigação, software e arquitetura de chips para ele. A alternativa seria tratá-lo como mais um nicho de computação científica.

D. Risco. O mercado era então minúsculo e académico. A IA já tinha tido vários "invernos" em que as promessas falharam. Desenhar chips especializados para IA (Tensor Cores) significava espaço de silício que não servia os jogos.

E. Execução. Bibliotecas específicas (cuDNN, 2014; TensorRT para inferência), trabalho direto com as equipas que criavam os frameworks (Caffe, TensorFlow, PyTorch), o servidor DGX-1 (2016) e a arquitetura Volta com Tensor Cores (2017).

F. Resultado. A receita de centros de dados multiplicou por cerca de dez entre os anos fiscais de 2016 e 2020. As grandes empresas de internet passaram a comprar GPU em volume para recomendação, pesquisa e tradução.

G. Impacto duradouro. Quando os modelos de linguagem surgiram (a arquitetura Transformer é de 2017), já estavam escritos em frameworks otimizados para GPU NVIDIA.

H. Lição. A NVIDIA não inventou o deep learning, mas foi a primeira grande empresa a reconhecê-lo como uma mudança de plataforma e a reorganizar-se à volta dele. Reconhecer cedo um sinal vindo de fora da empresa pode valer tanto como inventar.

3.4 A compra da Mellanox (2019–2020)

A. Contexto. Os modelos de IA estavam a crescer mais depressa do que a capacidade de uma única GPU. Treinar um modelo grande passou a exigir centenas ou milhares de GPU a trabalhar em conjunto, trocando dados constantemente.

B. Problema. Num cluster grande, o limite deixa de ser a velocidade de cada GPU e passa a ser a rede que as liga. Quem controlasse a rede controlaria o desempenho do sistema.

C. Decisão. Comprar a Mellanox por 6,9 mil milhões de dólares, vencendo a Intel, que também estava interessada. A alternativa era continuar a depender de parceiros de rede e de padrões abertos como a Ethernet.

D. Risco. Era a maior aquisição da história da empresa até então (cerca de dois terços da caixa disponível), num setor diferente e com aprovação necessária da China. A integração de uma cultura israelita independente era incerta.

E. Execução. A NVIDIA manteve a equipa e a liderança técnica (Michael Kagan tornou-se CTO), integrou o InfiniBand nos seus sistemas DGX e desenvolveu DPU (BlueField) e, mais tarde, a plataforma Ethernet Spectrum-X para clientes que não queriam InfiniBand.

F. Resultado. A rede tornou-se um negócio próprio de grande dimensão. Segundo as análises dos resultados do primeiro trimestre do ano fiscal de 2027, a receita de redes chegou a 14,8 mil milhões de dólares num único trimestre, quase o triplo do ano anterior (Global Data Center Hub).

G. Impacto duradouro. Permitiu à NVIDIA vender o centro de dados como um sistema integrado (GPU + CPU + rede + software), o que é muito mais difícil de substituir peça a peça.

H. Lição. As melhores aquisições compram uma peça que se vai tornar o estrangulamento do sistema antes de o mercado o perceber. A Mellanox é provavelmente uma das aquisições mais rentáveis da história dos semicondutores.

3.5 A tentativa falhada de comprar a Arm (2020–2022)

A. Contexto. A SoftBank queria vender a Arm, que licencia a arquitetura de processadores usada em quase todos os telemóveis e cada vez mais em servidores.

B. Oportunidade. Controlar a Arm daria à NVIDIA um CPU para combinar com as suas GPU e influência sobre todo o ecossistema de processadores.

C. Decisão. Oferta de 40 mil milhões de dólares, maioritariamente em ações. A alternativa, que acabou por ser seguida, era simplesmente licenciar a arquitetura Arm como qualquer outro cliente.

D. Risco. Regulatório, sobretudo: a Arm vende a todos os concorrentes da NVIDIA (Qualcomm, Apple, Amazon, Google), que temiam perder a neutralidade.

E. Execução. A FTC norte-americana processou para bloquear o negócio, o Reino Unido abriu uma investigação de segurança nacional e a UE e a China levantaram objeções.

F. Resultado. Abandono em fevereiro de 2022 e um encargo de cerca de 1,4 mil milhões de dólares pelo pagamento antecipado não recuperável.

G. Impacto duradouro. Menor do que parecia. A NVIDIA desenhou o CPU Grace (anunciado em 2021) com licença Arm e integrou-o nos superchips Grace Hopper e Grace Blackwell. Obteve quase tudo o que queria do ponto de vista técnico sem pagar 40 mil milhões. Pago em ações de 2020, o negócio teria custado uma fração significativa da empresa atual.

H. Lição. Um negócio falhado pode ser uma bênção. E a NVIDIA, já em 2020, era vista pela indústria e pelos reguladores como demasiado poderosa para comprar peças neutras do ecossistema: o escrutínio regulatório é hoje um limite estrutural ao seu crescimento por aquisição.

3.6 A crise de 2022, a H100 e o ChatGPT (2022–2023)

A. Contexto. Em 2022 a receita de jogos caiu com o fim das criptomoedas e da procura pandémica, houve abates de stock, os EUA restringiram exportações para a China e a ação perdeu cerca de dois terços do valor.

B. Problema e oportunidade. A gestão tinha de decidir se cortava investimento e encomendas à TSMC ou mantinha a aposta na nova geração para centros de dados (H100, arquitetura Hopper, com um motor específico para Transformers).

C. Decisão. Manter a H100 no calendário e garantir capacidade de produção e de empacotamento avançado. A empresa continuou também a contratar, ao contrário de muitos pares tecnológicos.

D. Risco. Se a procura de IA não se materializasse, a empresa ficaria com compromissos de compra elevados num mercado em queda.

E. Execução. A H100 começou a ser entregue em volume no final de 2022 e início de 2023, exatamente quando o ChatGPT desencadeou a corrida dos modelos de linguagem.

F. Resultado. Em maio de 2023 a NVIDIA previu 11 mil milhões de receita trimestral, contra cerca de 7 mil milhões esperados. A receita do ano fiscal de 2024 mais do que duplicou, e a margem bruta subiu de 57% para 73%.

G. Impacto duradouro. A NVIDIA passou de fornecedora de componentes a fornecedora crítica da maior vaga de investimento tecnológico desde a internet. O poder de fixação de preço tornou-se extraordinário.

H. Lição. O timing foi em grande parte sorte: ninguém na NVIDIA sabia que o ChatGPT seria lançado em novembro de 2022. O que não foi sorte foi estar preparada: ter o produto certo, a capacidade de produção e o software no momento em que a procura apareceu. Em ciclos, quem mantém o investimento durante a recessão captura a recuperação.

3.7 Blackwell, a cadência anual e os sistemas à escala do bastidor (2024–2026)

A. Contexto. Com a procura a exceder a oferta, os clientes queriam mais desempenho por dólar e por watt, e a Google, a Amazon e a Microsoft aceleravam os seus próprios chips. A AMD lançava as MI300.

B. Oportunidade. Aumentar a distância face aos concorrentes e capturar mais valor por centro de dados vendendo o bastidor inteiro, não apenas a GPU.

C. Decisão. Passar a uma arquitetura nova por ano (Blackwell em 2024–25, Blackwell Ultra em 2025, Rubin em 2026, Rubin Ultra e Feynman anunciados para depois) e lançar o GB200 NVL72, um bastidor com 72 GPU, 36 CPU, rede NVLink e refrigeração líquida, desenhado pela NVIDIA e montado por parceiros.

D. Risco. Complexidade de engenharia muito maior, risco de atrasos e de problemas de qualidade, e o risco de tornar obsoletos os produtos que os clientes acabaram de comprar.

E. Execução. Não foi isenta de problemas. Em 2024 o Blackwell teve uma falha de desenho no empacotamento que reduziu o rendimento de produção; Huang disse que a falha foi "100% culpa da NVIDIA" e que a TSMC ajudou a corrigi-la (Tom's Hardware). As entregas atrasaram cerca de um trimestre, e os primeiros bastidores NVL72 tiveram problemas de aquecimento e interligação no início de 2025. A margem bruta desceu de 75% para cerca de 71% no ano fiscal de 2026, em parte por custos de arranque.

F. Resultado. Apesar disso, o Blackwell tornou-se o produto de crescimento mais rápido da história da empresa, e em 2026 o Vera Rubin entrou em produção com bastidores já a funcionar na Microsoft, Google, Oracle, CoreWeave e Nebius (comunicado Q2 FY2027).

G. Impacto duradouro. A NVIDIA vende hoje fábricas de IA inteiras ("AI factories", na linguagem da empresa). Cada bastidor custa vários milhões de dólares, e a NVIDIA controla o desenho do sistema, o que dificulta a substituição por componentes de terceiros.

H. Lição. Uma empresa dominante pode usar a sua posição para acelerar em vez de abrandar, tornando mais difícil a vida aos concorrentes. Mas uma cadência anual também significa risco anual de execução: um ano mau numa geração abre espaço aos rivais.

3.8 A China: de mercado essencial a mercado perdido (2022–2026)

A. Contexto. A China chegou a representar mais de 20% da receita da NVIDIA. As grandes tecnológicas chinesas (Alibaba, Tencent, ByteDance, Baidu) eram clientes importantes.

B. Problema. A partir de outubro de 2022 o governo norte-americano restringiu sucessivamente a exportação de chips de IA avançados para a China, por razões de segurança nacional.

C. Decisão. A NVIDIA respondeu criando versões reduzidas que cumpriam cada novo limite (A800, H800, depois H20). A alternativa seria abandonar o mercado, deixando-o à Huawei.

D. Risco. Cada versão reduzida podia ser proibida pela regra seguinte, e foi o que aconteceu. Ao mesmo tempo, Pequim passou a pressionar as empresas chinesas a comprar chips nacionais.

E. Execução. Em abril de 2025 os EUA exigiram licença para o H20, o que levou a um encargo de 4,5 mil milhões de dólares em stock e compromissos (8-K FY2026). Em dezembro de 2025 Washington autorizou vendas do H200 mediante uma taxa de 25% para o Estado; mas em janeiro de 2026 as alfândegas chinesas bloquearam a entrada desses chips e as autoridades chinesas instruíram as empresas a não os comprar salvo necessidade (BusinessDay/Reuters).

F. Resultado. No segundo trimestre do ano fiscal de 2027, as vendas de H200 à China representaram menos de 1% da receita de centros de dados, segundo a reportagem da Bloomberg sobre os resultados (Bloomberg Tax). As previsões da empresa excluem a China.

G. Impacto duradouro. O crescimento global mais do que compensou a perda, mas a China está a desenvolver um ecossistema alternativo (Huawei Ascend, Cambricon) com um mercado interno cativo. Huang tem argumentado publicamente que as restrições aceleram a autonomia tecnológica chinesa.

H. Lição. Numa indústria estratégica, a geopolítica pode fechar um mercado inteiro independentemente da qualidade do produto. O risco não é apenas a perda de receita, mas o nascimento de um concorrente protegido.

3.9 De fornecedor a financiador do ecossistema (2025–2026)

A. Contexto. Com caixa abundante e clientes (laboratórios de IA, novas nuvens especializadas) com enormes necessidades de capital, a NVIDIA passou a usar o balanço como instrumento estratégico.

B. Oportunidade. Garantir que os maiores consumidores de computação continuam a comprar NVIDIA, e participar no valor criado por eles.

C. Decisão. Investimentos diretos: 5 mil milhões na Intel (2025), 30 mil milhões na OpenAI (2026), investimento na Anthropic (anunciado com a Microsoft no final de 2025), participações em nuvens especializadas como a CoreWeave, o acordo com a Groq (cerca de 20 mil milhões, segundo a imprensa) e plataformas de financiamento com gestores como a Apollo, BlackRock e KKR com o objetivo declarado de mobilizar mais de 500 mil milhões de capital de terceiros, ainda sujeitas a acordos definitivos. No final de julho de 2026 a NVIDIA detinha 42,8 mil milhões de dólares em títulos de capital cotados e a dívida subira para cerca de 33 mil milhões (comunicado Q2 FY2027).

D. Risco. O chamado "financiamento circular": se a NVIDIA investe num cliente que depois usa esse dinheiro para comprar GPU NVIDIA, parte da receita reportada é, em última análise, financiada pela própria NVIDIA. Se esses clientes não gerarem receitas suficientes, a NVIDIA perde duas vezes: na venda futura e no investimento.

E. Execução. A carta de intenções de até 100 mil milhões com a OpenAI (setembro de 2025) nunca se concretizou; Huang disse mais tarde que "nunca foi um compromisso" e o acordo final foi um investimento de capital de 30 mil milhões sem metas de implantação associadas (DatacenterDynamics).

F. Resultado. Ainda em curso. Não há dados suficientes para avaliar o retorno.

G. Impacto potencial. Aumenta a ligação da NVIDIA ao destino financeiro dos laboratórios de IA e torna os seus resultados mais sensíveis a uma eventual correção de avaliações no setor.

H. Lição. Quando um fornecedor começa a financiar os clientes, o investidor deve olhar com mais atenção para a qualidade da procura, e não apenas para a quantidade. Isto não significa que a procura seja artificial; significa que é preciso acompanhar quem paga, com que dinheiro, e se esses clientes geram receita própria.

4. Os maiores sucessos e os principais fracassos

O padrão da NVIDIA é claro: ganha quando aposta ag plataformas de computação onde pode controlar hardware e software ao mesmo tempo, e perde quando entra em mercados onde outro já controla a plataforma (telemóveis) ou quando tenta comprar peças neutras do ecossistema (Arm).

Sucessos

Sucesso	O que foi feito	Porque funcionou	Vantagem criada	Porque é difícil de copiar	Fator principal
CUDA (2006–)	Plataforma para programar GPU para qualquer cálculo paralelo, em todas as GPU	Base instalada enorme graças aos jogos; investimento persistente em bibliotecas e comunidade	Custos de mudança e efeitos de rede entre programadores, bibliotecas e hardware	Exige quase duas décadas de software acumulado e uma comunidade que não se compra	Inovação + persistência + timing
GeForce e o domínio dos jogos (1999–)	Liderança contínua em placas gráficas para PC, cerca de 80–90% da quota em placas dedicadas segundo estimativas setoriais	Ritmo de inovação, controladores de software fiáveis, relação próxima com estudos de jogos	Marca entre jogadores; escala que financia I&D	O mercado só comporta dois ou três concorrentes; a Intel entrou com as Arc e ganhou pouca quota	Execução + escala
Reorientação para a IA (2012–2017)	cuDNN, DGX, Tensor Cores, colaboração com frameworks	Reconheceu cedo um sinal externo e adaptou toda a empresa	Ficou como padrão de facto quando a IA generativa surgiu	Os concorrentes chegaram com cinco a dez anos de atraso	Timing + visão
Mellanox (2019–2020)	Compra da líder em redes de alto desempenho	A rede tornou-se o estrangulamento dos clusters de IA	Venda de sistemas completos	Concorrentes de rede (Broadcom, Arista) não têm a GPU; concorrentes de GPU não tinham a rede	Antecipação estratégica

Sucesso	O que foi feito	Porque funcionou	Vantagem criada	Porque é difícil de copiar	Fator principal
Sistemas à escala do bastidor (2024–)	GB200/GB300 NVL72, Vera Rubin	Os clientes querem capacidade pronta a funcionar, não componentes	Mais valor capturado por centro de dados; integração difícil de substituir	Exige excelência simultânea em chips, rede, energia, refrigeração e software	Execução + integração
Gestão da cadeia de abastecimento (2023–)	Reserva antecipada de capacidade na TSMC (fabrico e empacotamento CoWoS) e memória HBM	Numa fase de escassez, quem tem capacidade reservada vende	Concorrentes limitados pela oferta, não pela procura	Exige balanço, credibilidade e relações de décadas com fornecedores	Escala + relações

Fracassos e decisões controversas

NV1 (1995). Arquitetura proprietária incompatível com o padrão que o mercado adotou. Quase levou à falência. A lição — seguir o ecossistema dominante e competir na execução — moldou a década seguinte. Ironicamente, a NVIDIA viria mais tarde a vencer precisamente por criar o seu próprio padrão (CUDA); a diferença é que, desta vez, não havia um padrão estabelecido a combater.

GeForce FX / NV30 (2003). Chegou atrasada e inferior à Radeon 9700 da ATI. Custou quota de mercado durante cerca de dois anos. Mostrou que a liderança técnica numa indústria de ciclos curtos nunca está garantida.

Chips defeituosos para portáteis (2008). Encargo de cerca de 200 milhões de dólares e danos de reputação junto de fabricantes como a HP e a Dell; problema de materiais de empacotamento. Contribuiu para a perda de contratos de chips gráficos em portáteis da Apple na década seguinte, segundo vários relatos da indústria.

Telemóveis: Tegra e Icera (2008–2015). A NVIDIA quis repetir no telemóvel o sucesso dos PCs. Falhou porque a Qualcomm integrava o modem no mesmo chip (e a Icera comprada em 2011 por cerca de 367 milhões nunca chegou a competir) e porque os principais fabricantes passaram a desenhar os seus próprios processadores. O custo foi sobretudo de oportunidade: anos de atenção da gestão e de engenheiros. A NVIDIA reconheceu o erro, saiu, e reaproveitou a tecnologia na Nintendo Switch (mais de 150 milhões de consolas vendidas) e no automóvel.

Criptomoedas (2017–2022). A NVIDIA beneficiou da procura de mineiros e, quando o mercado colapsou, ficou com excesso de stock nos canais. A multa da SEC (5,5 milhões) foi pequena, mas o episódio mostra que parte da receita podia ter uma natureza

especulativa que a empresa não explicou bem aos investidores. A resposta (versões com mineração limitada e uma linha separada para mineiros) teve eficácia limitada.

Arm (2020–2022). Custou cerca de 1,4 mil milhões e um ano e meio de esforço regulatório. O fracasso foi, em termos líquidos, provavelmente benéfico (ver 3.5).

Automóvel. A NVIDIA promete há mais de uma década que o automóvel será um grande negócio. No ano fiscal de 2026 rendeu 2,3 mil milhões, cerca de 1% da receita. Não é um fracasso, mas é uma promessa que tem avançado muito mais devagar do que o anunciado, e um aviso sobre a diferença entre a visão de Huang e o calendário real dos mercados.

Atrasos do Blackwell (2024–2025). Uma falha de desenho atrasou as entregas e os primeiros bastidores tiveram problemas de fiabilidade. O custo foi limitado porque a procura era enorme e os concorrentes estavam longe, mas mostrou o risco de uma cadência de lançamento cada vez mais agressiva.

Capacidade de reconhecer erros

A NVIDIA tem um historial raro de admitir publicamente erros próprios e corrigir o rumo depressa: o pedido à Sega, a saída dos telemóveis, o reconhecimento de que a falha do Blackwell foi "100% culpa da NVIDIA". A exceção notável é a gestão da comunicação sobre criptomoedas, onde a SEC concluiu que a divulgação foi insuficiente.

5. O negócio: como a NVIDIA realmente ganha dinheiro

A NVIDIA vende capacidade de computação para IA, empacotada em chips, placas, servidores e bastidores inteiros, mais o software e a rede que os tornam utilizáveis. Desenha tudo, mas não fabrica nada: a TSMC produz os chips, a SK hynix, a Samsung e a Micron fornecem a memória, e fabricantes como a Foxconn, a Quanta, a Wistron, a Dell ou a Supermicro montam os sistemas. A NVIDIA fica com a parte mais valiosa da cadeia: a propriedade intelectual e o controlo da plataforma.

O que vende exatamente

Segmento (desde o ano fiscal de 2027)	O que inclui	Peso na receita (2.º trimestre do ano fiscal de 2027, maio–julho de 2026)
Data Center — computação	GPU (Blackwell, Rubin), CPU Grace/Vera, sistemas HGX/DGX, bastidores NVL72	Cerca de 92% da receita total em conjunto com a rede (89,0 de 96,2 mil milhões)

Segmento (desde o ano fiscal de 2027)	O que inclui	Peso na receita (2.º trimestre do ano fiscal de 2027, maio–julho de 2026)
Data Center — rede	NVLink, InfiniBand, Ethernet Spectrum-X, placas de rede e DPU, ótica	Incluída acima; no 1.º trimestre, 14,8 de 75,3 mil milhões (cerca de 20% do Data Center)
Edge Computing	GeForce (jogos), RTX para estações de trabalho, chips para automóvel, robótica, Nintendo Switch, estações de rede móvel com IA	7,2 mil milhões (cerca de 7,5%)

Fontes: comunicado Q2 FY2027; Global Data Center Hub para a divisão computação/rede do 1.º trimestre.

O software (CUDA e as bibliotecas) é em grande parte gratuito. A NVIDIA cobra licenças em produtos como o NVIDIA AI Enterprise e serviços como o DGX Cloud, mas esta receita é pequena face ao hardware. O papel económico do software não é gerar receita direta, é fazer com que o hardware NVIDIA seja a escolha por defeito.

Quem são os clientes

Desde o ano fiscal de 2027 a NVIDIA divide os clientes de centros de dados em dois grupos com peso quase igual (1.º trimestre: 37,9 e 37,4 mil milhões de dólares):

1. **Hyperscale**: os grandes fornecedores de nuvem pública e as maiores empresas de internet — Microsoft, Amazon, Google, Meta, Oracle e outros. Alugam a capacidade aos seus clientes (por exemplo, OpenAI e Anthropic) ou usam-na internamente (recomendação, publicidade, modelos próprios).
2. **AI Clouds, Industrial and Enterprise (ACIE)**: novas nuvens especializadas em IA (CoreWeave, Nebius, Lambda), laboratórios de modelos, projetos de "IA soberana" financiados por governos (Arábia Saudita, Emirados, Japão, Coreia, países europeus) e empresas que instalam sistemas nas suas próprias instalações.

Concentração. No ano fiscal de 2026 um único cliente direto representou 22% da receita total e outro 14% (10-K FY2026). Clientes "diretos" são muitas vezes os montadores (como a Foxconn ou a Quanta) que compram os chips e vendem os sistemas às grandes nuvens; os clientes finais por trás deles são, em grande parte, as mesmas quatro ou cinco empresas. A concentração real no cliente final é elevada.

Porque escolhem a NVIDIA

Para um cliente que gasta dezenas de milhares de milhões em centros de dados, o preço do chip é apenas uma parte do custo. O que importa é o custo total por unidade de trabalho útil: quantos "tokens" (as unidades de texto que um modelo lê ou gera) por dólar e por watt, incluindo energia, edifício, rede, engenheiros e tempo até estar a funcionar. A NVIDIA ganha porque:

- **Desempenho por watt.** Num centro de dados limitado pela energia disponível, o chip mais eficiente gera mais receita com a mesma ligação à rede elétrica. Huang resumiu isto no comunicado de agosto de 2026: "a computação é receita".
- **Software pronto.** Os modelos e frameworks funcionam primeiro e melhor em NVIDIA. Mudar de fornecedor exige meses de trabalho de engenharia e traz risco.
- **Disponibilidade e prazo.** A NVIDIA entrega o sistema completo e validado, e tem capacidade reservada na cadeia de abastecimento.
- **Flexibilidade.** Uma GPU NVIDIA serve para treinar, servir modelos, simular e para várias gerações de modelos. Um chip especializado pode ser mais barato para uma tarefa específica, mas é uma aposta de que a tarefa não muda.
- **Liquidez.** Para uma nuvem que aluga capacidade, GPU NVIDIA são o produto que os clientes pedem, fáceis de alugar e com valor residual.

Do investimento ao dinheiro em caixa

O ciclo económico de uma geração de produtos dura vários anos:

1. **I&D (três a cinco anos antes da venda).** A NVIDIA desenha a arquitetura, o chip, o sistema e o software. As despesas operacionais totais foram de cerca de 23 mil milhões de dólares no ano fiscal de 2026 (cerca de 11% da receita), maioritariamente I&D.
2. **Compromissos com fornecedores (um a dois anos antes).** Para garantir produção, a NVIDIA compromete-se a comprar capacidade de fabrico, empacotamento e memória, muitas vezes com pagamentos antecipados. É aqui que está o maior risco: se a procura cair, os compromissos ficam.
3. **Produção e inventário (meses).** A TSMC fabrica os chips, que são empacotados com memória HBM; os montadores integram-nos em placas e bastidores.
4. **Venda e cobrança.** A NVIDIA fatura os montadores ou os clientes e recebe normalmente em poucas semanas a alguns meses. O fluxo de caixa operacional trimestral oscila com os movimentos de inventário e pagamentos antecipados: foi de 50,3 mil milhões no 1.º trimestre do ano fiscal de 2027 e de 24,1 mil milhões no 2.º, apesar de o lucro ter sido semelhante nos dois trimestres.

Como não tem fábricas, o investimento em ativos fixos é muito baixo (6,0 mil milhões no ano fiscal de 2026, menos de 3% da receita). Quase todo o lucro se transforma em caixa.

O que determina as margens

A margem bruta (receita menos custo dos produtos vendidos) andou entre 71% e 75% nos últimos três anos, níveis típicos de empresas de software, não de hardware. Os fatores principais:

- **Poder de preço.** Enquanto a procura exceder a oferta e não houver alternativa equivalente, a NVIDIA fixa preços pelo valor que cria para o cliente, não pelo custo.
- **Mistura de produtos.** Vender bastidores completos inclui componentes de terceiros (memória, cabos, refrigeração) com margem menor do que a GPU, o que pode pressionar a percentagem mesmo que o lucro absoluto suba.
- **Arranque de novas gerações.** Rendimentos de produção baixos no início de cada geração reduzem a margem temporariamente (como no Blackwell em 2025).
- **Custo da memória.** A memória HBM é uma fatia crescente do custo de cada GPU, e os seus fornecedores têm poder negocial em períodos de escassez.
- **Encargos extraordinários.** Abates de stock (H20 em 2025) baixam a margem num trimestre.

A margem operacional, cerca de 60% no ano fiscal de 2026, reflete a alavancagem operacional: o I&D é um custo quase fixo, partilhado por um volume de vendas que se multiplicou.

Recorrente ou cíclico?

Quase nada na receita da NVIDIA é contratualmente recorrente. Os clientes compram hardware quando constroem centros de dados. O que existe é uma recorrência de facto: os grandes clientes renovam e expandem a frota a cada geração, e os compromissos plurianuais de clientes (por exemplo, a parceria anunciada com a Meta para “milhões” de GPU Blackwell e Rubin) dão visibilidade. Mas é, por natureza, um negócio de investimento de capital dos clientes: se eles abrandarem os seus gastos, a receita da NVIDIA cai, e cai mais do que proporcionalmente.

O que torna o negócio difícil de replicar

Três camadas que se reforçam: (1) chips com desempenho de topo, que exigem milhares de engenheiros e milhares de milhões por geração; (2) um ecossistema de software com quase vinte anos e milhões de programadores; (3) a capacidade de integrar e entregar sistemas completos à escala de centenas de milhares de unidades por trimestre, com a cadeia de abastecimento garantida. Um concorrente pode igualar uma camada; igualar as três em simultâneo é muito mais difícil.

O que poderia retirar-lhe clientes ou rentabilidade

- Os grandes clientes desenharem os seus próprios chips (TPU da Google, Trainium da Amazon, Maia da Microsoft, MTIA da Meta), muitas vezes com a Broadcom ou a Marvell, para as cargas de trabalho mais previsíveis.
- A AMD atingir paridade suficiente em hardware e software para ser uma segunda fonte credível, obrigando a NVIDIA a baixar preços.
- Uma mudança de ênfase do treino para a inferência (servir modelos), onde chips mais simples e baratos podem ser suficientes.
- Um abrandamento do investimento em IA, que transformaria escassez em excesso de oferta e destruiria o poder de preço.

6. Produtos, tecnologia e inovação

A vantagem tecnológica da NVIDIA não está num único produto, mas na acumulação de inovações em camadas diferentes do sistema. Para perceber o seu valor económico, convém perceber primeiro porque é que a IA precisa de GPU.

A ideia técnica essencial, em termos simples

Um CPU é como um pequeno grupo de especialistas muito versáteis: resolve qualquer tarefa, mas poucas de cada vez. Uma GPU é como um exército de milhares de trabalhadores simples que fazem todos a mesma operação em simultâneo sobre dados diferentes. Desenhar uma imagem 3D é esse tipo de tarefa (calcular a cor de milhões de píxeis); treinar uma rede neuronal também (multiplicar matrizes com milhares de milhões de números). Por isso a mesma tecnologia serviu os jogos e depois a IA.

Os produtos e inovações que importam

Inovação	Ano	Problema resolvido	Tipo	Efeito comercial
RIVA 128	1997	Aceleração 3D compatível com o padrão DirectX	Execução	Salvou a empresa
GeForce 256	1999	Transferiu geometria e iluminação do CPU para a GPU	Inovação real com marketing forte (“a primeira GPU”)	Liderança nos jogos
GPU programável (shaders)	2001	Efeitos visuais definidos pelo programador	Inovação do setor (NVIDIA e ATI)	Base para o CUDA

Inovação	Ano	Problema resolvido	Tipo	Efeito comercial
CUDA + G80	2006	Programar a GPU para qualquer cálculo em C	Inovação genuína de plataforma	Retorno lento, depois decisivo
cuDNN e bibliotecas de IA	2014–	Primitivas otimizadas para redes neuronais	Software incremental mas estratégico	Tornou a NVIDIA o padrão nos frameworks
NVLink	2016	Ligação rápida entre GPU, muito acima do PCIe	Inovação de interligação	Permite tratar várias GPU como uma só
Tensor Cores (Volta V100)	2017	Circuitos dedicados a multiplicação de matrizes	Especialização genuína	Salto de desempenho em IA
RTX (Turing)	2018	Traçado de raios em tempo real e DLSS (imagem melhorada por IA)	Inovação nos jogos	Diferenciação face à AMD
Transformer Engine (Hopper H100)	2022	Precisão FP8 ajustada automaticamente para modelos de linguagem	Especialização com timing perfeito	Produto da explosão de 2023
Grace (CPU Arm)	2023	CPU desenhado para alimentar GPU com dados	Integração	Sistemas completos sem Intel/AMD
Blackwell e NVL72	2024–25	Dois chips num só pacote; 72 GPU num bastidor funcionando como uma	Inovação de sistema	Maior produto da história da empresa
Vera Rubin	2026	Seis chips novos; a NVIDIA anuncia custo por token de inferência até 10 vezes inferior ao Blackwell	Gestão (por verificar em produção)	Em produção desde 2026

Porque a precisão numérica importa economicamente

Uma das inovações menos visíveis e mais valiosas foi reduzir o número de bits usados em cada cálculo: de 32 bits (FP32) para 16, 8 (FP8, no Hopper) e 4 (FP4, no Blackwell). As redes neuronais toleram números menos precisos sem perda relevante de qualidade, e cada redução para metade quase duplica o volume de cálculos por chip e por watt. Parte importante dos ganhos de desempenho anunciados pela NVIDIA nas últimas gerações vem daqui, e não apenas de transistores mais pequenos. O investidor deve ler com cuidado os números de desempenho de marketing, que muitas vezes comparam gerações em precisões diferentes.

A memória e o empacotamento: os verdadeiros estrangulamentos

As GPU de IA são rodeadas de memória HBM (high bandwidth memory), pilhas de chips de memória colocadas ao lado da GPU num mesmo pacote através do processo CoWoS da TSMC. Nos últimos anos, a capacidade de CoWoS e de HBM, mais do que a fabricação dos próprios chips, limitou as vendas. Por isso a parceria plurianual com a SK hynix anunciada em agosto de 2026 é estratégica.

A rede como produto

Num cluster de dezenas de milhares de GPU, uma parte crescente do tempo é gasta a trocar dados. A NVIDIA oferece três níveis: NVLink (dentro do bastidor), InfiniBand (entre bastidores, tradicional nos supercomputadores) e Spectrum-X (Ethernet otimizada para IA, para clientes que preferem padrões abertos). Esta é uma das áreas em que a NVIDIA compete diretamente com a Broadcom, outra empresa do portefólio.

O software: onde está o fosso

Além do CUDA, a NVIDIA mantém centenas de bibliotecas para domínios específicos (por exemplo, TensorRT-LLM para servir modelos de linguagem, Dynamo para orquestrar inferência distribuída, Omniverse para simulação, Isaac para robótica, cuQuantum para computação quântica simulada) e modelos próprios abertos (família Nemotron, Cosmos para IA física). Cada biblioteca aumenta o custo de mudar para outro fornecedor.

Deve notar-se uma nuance importante: a maioria dos programadores de IA já não escreve CUDA diretamente; escreve em PyTorch ou JAX, e são esses frameworks que chamam o CUDA. Isto significa que, se os frameworks e os compiladores (como o Triton, da OpenAI) suportarem bem outro hardware, o fosso do CUDA enfraquece. A NVIDIA responde mantendo-se à frente na otimização e contribuindo ativamente para esses projetos.

Inovação técnica versus vantagem comercial

Nem toda a inovação da NVIDIA se traduziu em vantagem comercial. O NV1 era tecnicamente original e fracassou. Os Tegra eram competitivos em desempenho e perderam por razões de integração e de canal. O DRIVE para automóvel é tecnicamente avançado mas tem crescido devagar, porque os ciclos da indústria automóvel são longos e os fabricantes resistem a entregar o "cérebro" do carro a um fornecedor externo. O Omniverse (simulação e gémeos digitais) ainda não é um negócio significativo. A inovação converteu-se em vantagem comercial quando três condições se juntaram: um mercado grande, um ecossistema que a NVIDIA controlava, e o facto de o cliente pagar pelo desempenho.

7. Aquisições, parcerias e decisões estratégicas

A NVIDIA cresceu sobretudo organicamente. Fez uma única grande aquisição concluída (Mellanox), falhou a maior que tentou (Arm) e, desde 2024, usa cada vez mais duas fórmulas alternativas: compras pequenas de empresas de software e acordos de licenciamento com contratação de equipas, que evitam o escrutínio de uma aquisição formal.

Aquisições e operações semelhantes

Operação	Ano	Preço (quando conhecido)	Motivo	Avaliação
3dfx (ativos e patentes)	2000	Cerca de 70 milhões em dinheiro mais ações	Eliminar o antigo líder, absorver engenheiros e patentes	Criou valor: consolidou a liderança nos jogos a baixo custo
PortalPlayer	2007	Cerca de 357 milhões	Entrar em dispositivos portáteis (fornecia chips do iPod)	Destruiu valor: a Apple já estava a abandonar a PortalPlayer
Ageia (PhysX)	2008	Não divulgado	Física em tempo real para jogos, correndo em CUDA	Modesto: o PhysX tornou-se uma funcionalidade, não um negócio
Icera	2011	Cerca de 367 milhões	Modems para competir com a Qualcomm em telemóveis	Destruiu valor: encerrada em 2015

Operação	Ano	Preço (quando conhecido)	Motivo	Avaliação
Mellanox	2019–20	6,9 mil milhões	Redes de alto desempenho para clusters	Criou muito valor (ver 3.4)
Cumulus, SwiftStack, Bright Computing	2020–22	Pequenas	Software de rede, armazenamento e gestão de clusters	Complementos úteis, impacto difícil de isolar
Arm	2020–22	40 mil milhões (abandonada)	CPU e controlo do ecossistema	Falhada; custo de cerca de 1,4 mil milhões (ver 3.5)
Run:ai	2024	Cerca de 700 milhões (segundo a imprensa)	Software de orquestração de GPU; aprovado pela Comissão Europeia após análise	Cedo para avaliar; a NVIDIA tornou parte do software aberto
Enfabrica (licença + equipa)	2025	Mais de 900 milhões (segundo a imprensa)	Tecnologia de interligação e engenheiros	Cedo para avaliar
Groq (licença não exclusiva + equipa)	Dez. 2025	Cerca de 20 mil milhões (segundo a imprensa; saída de caixa de 13 mil milhões no ano fiscal de 2026)	Tecnologia de inferência de baixa latência e a equipa de Jonathan Ross, um dos criadores da TPU da Google	Cedo para avaliar; o acelerador Groq 3 LPX já está em produção

Sobre a Groq: a NVIDIA insiste que não se trata de uma aquisição, e a Groq continua a existir como empresa independente com o seu serviço de nuvem. Comentadores descreveram estruturas deste tipo como aquisições de facto que contornam a revisão de concorrência (Constellation Research; TechSpot). A lógica estratégica é clara: a inferência (servir modelos) é o segmento onde arquiteturas alternativas à GPU são mais competitivas, e a NVIDIA preferiu absorver uma delas a deixá-la crescer. O risco é regulatório: este tipo de operação está a atrair a atenção das autoridades de concorrência nos EUA e na Europa.

Investimentos em capital de clientes e parceiros

Investimento	Data	Montante	Lógica
OpenAI	2026	30 mil milhões (em vez dos até 100 mil milhões da carta de intenções de 2025)	Assegurar o maior consumidor de computação de IA
Anthropic	Anunciado no fim de 2025	Até 10 mil milhões, segundo o anúncio conjunto com a Microsoft	A Anthropic usa sobretudo TPU da Google e Trainium da Amazon; o acordo inclui compromissos de uso de sistemas NVIDIA
Intel	2025	5 mil milhões	Desenvolvimento conjunto de processadores x86 com GPU NVIDIA integrada e CPU personalizados para centros de dados
Nokia, Synopsys, CoreWeave, xAI e outros	2023–26	De centenas de milhões a alguns mil milhões	Redes móveis com IA, software de desenho de chips, nuvens especializadas, laboratórios

Estes investimentos são, em parte, defensivos (garantir que os grandes compradores de computação não migram para alternativas) e, em parte, uma forma de reciclar caixa abundante. A crítica é a do “financiamento circular” (ver 3.9 e secção 12).

Parcerias decisivas

- **TSMC (desde 1997–98).** A parceria mais importante da história da empresa. Permitiu à NVIDIA nunca investir em fábricas e ter acesso aos processos mais avançados. A contrapartida é uma dependência quase total de um fornecedor em Taiwan, parcialmente mitigada pela produção da TSMC no Arizona, que começou a fabricar chips Blackwell em 2025.
- **Microsoft (Xbox, 2001; Azure, hoje).** A Xbox deu escala no início dos anos 2000. Hoje a Microsoft é um dos maiores clientes e também um concorrente potencial (chips Maia).
- **Nintendo (Switch, 2017; Switch 2, 2025).** Deu uma segunda vida à tecnologia Tegra.

- **Fabricantes de sistemas (Foxconn, Quanta, Wistron, Dell, HPE, Supermicro).** A NVIDIA depende deles para montar os bastidores; eles dependem da NVIDIA para a maior parte do seu crescimento.
- **Fornecedores de memória (SK hynix, Samsung, Micron).** A parceria plurianual com a SK hynix (2026) procura garantir HBM.
- **Plataformas de financiamento (2026).** Acordos com Apollo, BlackRock, Blackstone, Brookfield, Goldman Sachs e KKR para mobilizar mais de 500 mil milhões de capital de terceiros para centros de dados, ainda sujeitos a acordos definitivos. Se concretizados, reduzem a dependência da procura da NVIDIA do balanço dos seus clientes, mas aumentam a ligação ao ciclo de crédito.

Desinvestimentos e saídas

A NVIDIA sai de negócios sem grandes vendas: encerrou os chipsets para PC (após o litígio com a Intel), os telemóveis e a Icera, e o serviço de streaming de jogos (GeForce Now) foi mantido mas com papel menor. A disciplina de saída é boa; a disciplina de entrada, nos anos 2000, foi mais fraca (PortalPlayer, Icera).

8. A concorrência e a vantagem competitiva

A NVIDIA domina os aceleradores de IA comerciais (as estimativas setoriais mais citadas apontam para 80% a 90% da receita do segmento), mas a ameaça principal não vem de quem vende chips concorrentes. Vem dos seus próprios clientes, que desenham chips internos para reduzir a dependência e o custo.

Os concorrentes, por tipo

Concorrente	Mercado	Onde é forte	Onde é fraco face à NVIDIA
AMD (Instinct MI300/MI350/MI400, bastidor Helios)	GPU para centros de dados; também jogos (Radeon)	Hardware competitivo, mais memória por GPU, preço; acordo com a OpenAI (2025) para vários gigawatts	Software (ROCm) menos maduro; rede e sistemas completos mais recentes; escala menor

Concorrente	Mercado	Onde é forte	Onde é fraco face à NVIDIA
Google (TPU)	Chips próprios, usados internamente e alugados na Google Cloud; acordos com a Anthropic	Dez anos de experiência (desde 2015), integração com o software da Google (JAX), custo	Só disponível na nuvem da Google; menos flexível fora do ecossistema Google
Amazon (Trainium, Inferentia)	Chips próprios na AWS; grande cluster para a Anthropic	Controlo do custo dentro da maior nuvem do mundo	Ecossistema de software menor; os clientes da AWS continuam a pedir NVIDIA
Microsoft (Maia) e Meta (MTIA)	Chips internos	Otimização para cargas específicas (recomendação, inferência de modelos próprios)	Programas mais recentes, menor escala
Broadcom e Marvell	Desenho de chips personalizados (ASIC) para as grandes nuvens; redes Ethernet	A Broadcom é o parceiro de desenho da TPU e de outros chips; líder em switches Ethernet	Não vende uma plataforma geral; depende de clientes que também compram NVIDIA
Huawei (Ascend), Cambricon e outros na China	Mercado chinês	Mercado protegido, apoio estatal	Limitados no acesso aos processos de fabrico mais avançados e à HBM
Startups (Cerebras, SambaNova, Tenstorrent, Etched)	Nichos, sobretudo inferência	Arquiteturas originais, velocidade em tarefas específicas	Escala, software, capacidade de entrega
Intel (Gaudi; GPU)	Centros de dados e jogos (Arc)	Base de clientes em CPU	Sucessivos atrasos; hoje também parceira da NVIDIA

As vantagens competitivas, uma a uma

1. Custos de mudança no software (estrutural, mas a erodir lentamente). O CUDA e as bibliotecas representam quase vinte anos de trabalho. Mudar exige reescrever e reotimizar código, validar resultados e retreinar equipas. A erosão vem dos frameworks (PyTorch, JAX) e compiladores (Triton) que abstraem o hardware: para o grande laboratório com engenheiros dedicados, mudar é cada vez mais viável; para a empresa média, continua a ser caro.

2. Efeitos de rede no ecossistema (estrutural). Mais utilizadores atraem mais bibliotecas, mais investigação publicada com código para NVIDIA, mais engenheiros formados em CUDA, o que atrai mais utilizadores. Os novos modelos e técnicas aparecem primeiro otimizados para NVIDIA.

3. Escala em I&D (estrutural enquanto as receitas se mantiverem). Com 216 mil milhões de receita anual, a NVIDIA pode gastar em I&D mais do que a receita total de quase todos os concorrentes especializados, e suportar uma arquitetura nova por ano.

4. Integração de sistema (estrutural, reforçada desde 2024). GPU, CPU, NVLink, rede, software e desenho do bastidor otimizados em conjunto. A Google tem algo semelhante, mas apenas para si própria.

5. Acesso à cadeia de abastecimento (temporária mas importante). Capacidade reservada na TSMC (CoWoS) e na HBM. Em períodos de escassez, quem tem capacidade vende; quando a oferta deixar de ser limitada, esta vantagem diminui.

6. Marca e confiança dos gestores de compras (moderada). “Ninguém é despedido por comprar NVIDIA”, como era dito sobre a IBM nos anos 70. Funciona enquanto o desempenho se mantiver.

7. Velocidade de inovação (cultural, depende das pessoas). A cadência anual obriga os rivais a acertar num alvo em movimento.

Onde a NVIDIA é mais forte e mais fraca

- **Mais forte:** treino de modelos de fronteira; clientes que precisam de flexibilidade (vários modelos, cargas que mudam); nuvens que alugam capacidade a terceiros; empresas e governos sem engenharia de chips própria.
- **Mais fraca:** inferência em grande volume de modelos estáveis dentro de uma grande nuvem, onde um chip próprio ou personalizado pode ser mais barato; a China; segmentos onde o preço é o critério principal.

Quanto tempo e capital para replicar?

Inferência analítica: construir um chip competitivo numa geração é possível com alguns milhares de milhões e três a quatro anos, como mostram a AMD, a Google ou a Amazon. Construir o conjunto chip + rede + software + ecossistema + cadeia de abastecimento à escala da NVIDIA exigiria provavelmente uma década e dezenas de milhares de milhões, e mesmo assim não garantiria a adoção pelos programadores. A Google, que começou em 2015, é o exemplo mais próximo de sucesso, e mesmo assim continua a comprar GPU NVIDIA para a sua nuvem.

O que poderia enfraquecer as vantagens

- Padrões abertos de interligação (UALink, Ultra Ethernet) apoiados pela AMD, Broadcom, Intel e grandes nuvens, que permitam combinar componentes de vários fornecedores.
- A maturidade dos compiladores e frameworks que tornam o hardware intermutável.
- A transição da IA para cargas de inferência padronizadas, onde a especialização vence a flexibilidade.
- O fim da escassez: com oferta abundante, os clientes negociam preço e diversificam fornecedores.
- Uma mudança de paradigma na arquitetura dos modelos que favoreça outro tipo de hardware.

Estrutural versus temporário. O ecossistema de software, a integração de sistema e a escala de I&D são estruturais. As margens brutas de 75% e a posição de fornecedor quase único são, em grande parte, consequência de um desequilíbrio temporário entre procura e oferta. O investidor deve esperar que a quota e as margens diminuam com o tempo, mesmo num cenário favorável; a questão é a que ritmo.

9. A cultura empresarial e a forma de trabalhar

A NVIDIA é uma organização muito plana, muito exigente e muito centrada no CEO, com cerca de 42 mil trabalhadores no fim do ano fiscal de 2026, dos quais 31 mil em I&D (10-K FY2026). Isto dá cerca de 5 milhões de dólares de receita por trabalhador, um valor raro mesmo entre as tecnológicas.

Os princípios, tal como descritos por Huang e por antigos executivos

As práticas abaixo são descritas pelo próprio Huang em entrevistas extensas (por exemplo, no podcast *Acquired* e em conferências como a Stripe Sessions de 2024) e na biografia de Tae Kim. São relatos de dentro da empresa; não há forma independente de verificar até que ponto são aplicados em toda a organização.

- **Estrutura plana.** Huang tem cerca de sessenta subordinados diretos e diz não fazer reuniões individuais regulares com eles. A lógica declarada é que a informação deve chegar a todos ao mesmo tempo, sem camadas de gestão a filtrá-la.
- **“Top 5 Things”.** Qualquer trabalhador pode enviar um email curto com as cinco coisas mais importantes em que está a trabalhar ou que está a observar no mercado. Huang lê uma parte significativa destes emails e usa-os como sistema de informação direta, contornando a hierarquia.
- **Crítica em público.** Huang diz preferir dar feedback em reuniões abertas para que todos aprendam com o erro. É uma prática eficaz na difusão de critérios, mas que os relatos de antigos trabalhadores descrevem como intimidante.
- **“A missão é o chefe.”** Os projetos são organizados em torno de objetivos, não de departamentos; as equipas formam-se e desfazem-se conforme o problema.
- **“Velocidade da luz”.** Para cada projeto, a pergunta é qual seria o limite teórico (quanto tempo levaria, quanto custaria, se tudo corresse perfeitamente) e não qual foi o resultado do ano anterior. É uma forma de evitar melhorias incrementais confortáveis.
- **Sem planos a cinco anos.** A empresa não faz planeamento rígido de longo prazo nem revisões periódicas formais; o planeamento é contínuo e ajustado ao que se aprende.
- **Honestidade intelectual sobre falhas.** O episódio Sega, a saída dos telemóveis e a admissão pública sobre o Blackwell ilustram uma disposição de reconhecer erros depressa.

Centralização e tomada de decisão

As grandes apostas são decididas por Huang, que também faz a maior parte da comunicação externa (conferência GTC, CES, Computex). Ao mesmo tempo, a estrutura plana dá autonomia aos engenheiros dentro de cada projeto. O resultado é uma empresa muito rápida nas decisões estratégicas e muito dependente do julgamento de uma pessoa. Com 42 mil trabalhadores e receitas que se multiplicaram por oito em três anos, uma questão legítima é se este modelo escala sem perder velocidade.

Recrutamento, recompensa e retenção

- A rotação de pessoal foi de 3,7% no ano fiscal de 2026, segundo o 10-K, muito abaixo do habitual no setor dos semicondutores. Mais de 40% das contratações vieram de recomendações de trabalhadores.
- A remuneração em ações, combinada com a valorização da ação desde 2023, tornou uma parte significativa dos trabalhadores muito ricos. Isto retém talento (as ações são atribuídas ao longo de vários anos), mas cria um risco descrito na imprensa como “descansar à espera das ações” (rest and vest): pessoas que ficam pela riqueza diferida e não pela motivação.

- A empresa tem fama de exigir horas longas. Reportagens (por exemplo, da Bloomberg em 2024) descreveram ambientes de grande pressão em algumas equipas; outros relatos sublinham a autonomia e a intensidade intelectual.

A influência do fundador

A cultura é indistinguível de Huang: o lema dos "trinta dias para falir", a obsessão pela velocidade, a disposição de apostar em mercados que ainda não existem. Huang tem dito que planeia continuar à frente da empresa por muitos anos. A sucessão não é discutida publicamente, o que é um risco de governação (ver secção 12).

Críticas relevantes

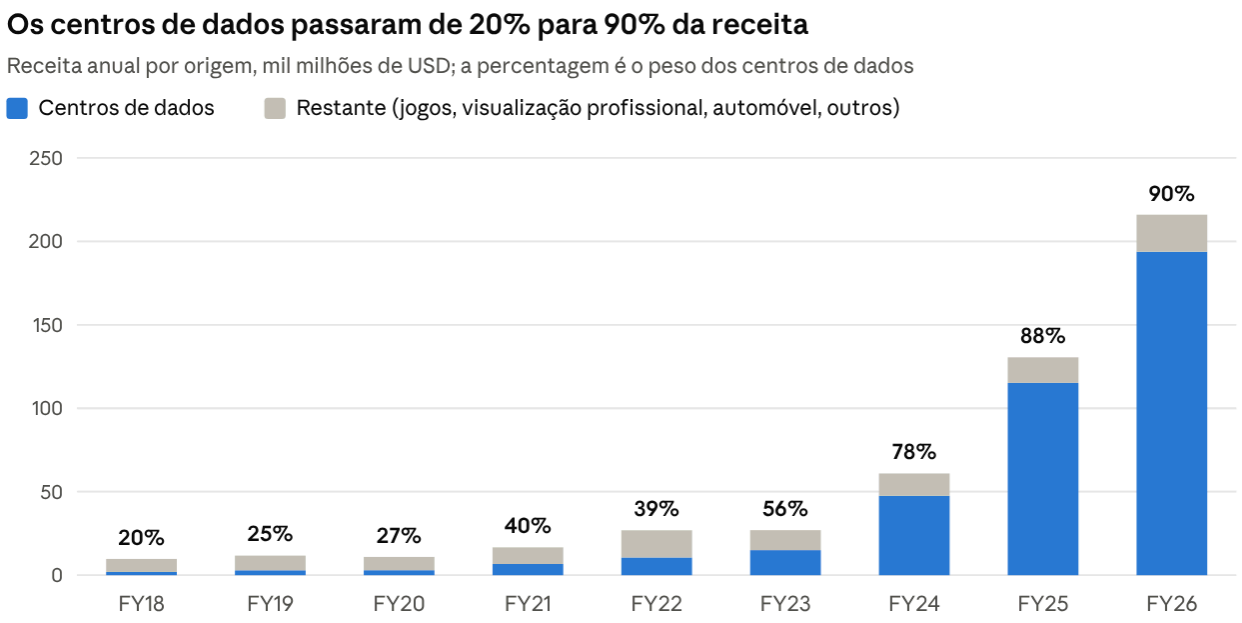
- **Governação.** Vários administradores estão no conselho há mais de duas décadas, o que levanta dúvidas sobre a capacidade de fiscalizar um CEO-fundador tão dominante.
- **Relacionamento com parceiros.** Há relatos de fabricantes de placas gráficas que se queixam da pressão comercial da NVIDIA; a EVGA, parceira histórica, abandonou o negócio de placas gráficas em 2022 citando a relação com a NVIDIA.
- **Afetação de produto.** Em períodos de escassez, a NVIDIA decide quem recebe GPU e quando. Clientes e concorrentes acusaram-na de favorecer nuvens mais pequenas em que investe (como a CoreWeave) face às grandes nuvens que desenvolvem chips concorrentes. Estas acusações foram referidas em investigações de concorrência, sem conclusão pública até à data.

Relação entre cultura e resultados

A relação mais clara é a velocidade: passar a uma arquitetura por ano exige uma organização capaz de coordenar milhares de engenheiros sem burocracia. A paciência com o CUDA também só foi possível porque o CEO tinha autoridade para ignorar a pressão de curto prazo. O lado negativo é a fragilidade: um modelo tão centrado numa pessoa é difícil de transmitir.

10. A evolução financeira

Em nove anos a NVIDIA passou de 9,7 para 215,9 mil milhões de dólares de receita e de 2,9 para 96,7 mil milhões de free cash flow. Quase todo esse salto aconteceu nos três últimos anos fiscais, e quase todo vem dos centros de dados.



Comunicados de resultados e 10-K da NVIDIA · anos fiscais 2018–2026 (terminam no fim de janeiro do ano indicado)

Os números essenciais (anos fiscais completos, mil milhões de USD)

Ano fiscal (fim)	Receita	Crescimento	Margem bruta	Margem operacional	Lucro líquido	Margem líquida	Fluxo de caixa operacional	Free cash flow	Caixa líquida
FY2026 (jan. 2026)	215,9	+65,5%	71,1%	60,4%	120,1	55,6%	102,7	96,7	54,1
FY2025 (jan. 2025)	130,5	+114,2%	75,0%	62,4%	72,9	55,8%	64,1	60,9	34,7
FY2024 (jan. 2024)	60,9	+125,9%	72,7%	54,1%	29,8	48,8%	28,1	27,0	16,3
FY2023 (jan. 2023)	27,0	+0,2%	56,9%	15,7%	4,4	16,2%	5,6	3,8	2,3
FY2022 (jan. 2022)	26,9	+61,4%	64,9%	37,3%	9,8	36,2%	9,1	8,1	10,3
FY2021 (jan. 2021)	16,7	+52,7%	62,3%	27,2%	4,3	26,0%	5,8	4,7	4,6

Ano fiscal (fim)	Receita	Crescimento	Margem bruta	Margem operacional	Lucro líquido	Margem líquida	Fluxo de caixa operacional	Free cash flow	Caixa líquida
FY2020 (jan. 2020)	10,9	−6,8%	62,0%	26,1%	2,8	25,6%	4,8	4,3	8,9
FY2019 (jan. 2019)	11,7	+20,6%	61,2%	32,5%	4,1	35,3%	3,7	3,1	5,4
FY2018 (jan. 2018)	9,7	+40,6%	59,9%	33,0%	3,0	31,4%	3,5	2,9	5,1

Valores GAAP. Free cash flow = fluxo de caixa operacional menos compras de ativos fixos e intangíveis. Caixa líquida = caixa e títulos de dívida negociáveis menos dívida financeira. Fontes: FY2018–19, FY2020–21, FY2022–26 (agregador, conferido com o 8-K FY2026). A margem operacional de FY2023 usa o valor GAAP reportado (4,2 mil milhões), que inclui o encargo da Arm.

Como ler estes números

Três regimes distintos. De FY2018 a FY2022 a NVIDIA era uma boa empresa de semicondutores: crescimento elevado mas irregular, margem bruta de 60–65%, margem operacional de 25–37%. FY2023 foi uma recessão cíclica. De FY2024 em diante, a empresa entrou num regime diferente, com margens operacionais acima de 50% — níveis de software, num negócio de hardware.

Quando acelerou. A aceleração começou no segundo trimestre de FY2024 (maio a julho de 2023). Antes disso, os centros de dados já cresciam depressa, mas a partir de valores modestos.

Quando desacelerou. FY2020 (fim da mineração de criptomoedas, excesso de stock) e FY2023 (fim da procura pandémica, segundo colapso das criptomoedas, abates de inventário, encargo de cerca de 1,4 mil milhões pela Arm). Os dois episódios mostram como as receitas de hardware podem estagnar de um ano para o outro.

Margens. A margem bruta saltou de 57% para 73% num ano (FY2024) e chegou a 75% em FY2025. A descida para 71% em FY2026 explica-se por dois fatores identificáveis: o encargo de 4,5 mil milhões pelo H20 (cerca de dois pontos percentuais) e os custos de arranque do Blackwell. Nos dois primeiros trimestres de FY2027 a margem voltou a cerca de 75%.

Lucro convertido em caixa. O free cash flow acompanha de perto o lucro líquido (96,7 contra 120,1 mil milhões em FY2026). A diferença vem sobretudo de inventário e pagamentos antecipados a fornecedores, não de investimento em fábricas. Este é um dos traços mais fortes do negócio.

O que é recorrente e o que é extraordinário. Há encargos pontuais identificáveis (Arm em FY2023, H20 em FY2026) e ganhos não operacionais crescentes vindos da valorização de participações em empresas cotadas e não cotadas. No 2.º trimestre de FY2027, o lucro por ação GAAP (2,46 dólares) foi superior ao não-GAAP (2,22), o que indica ganhos não operacionais importantes. À medida que a carteira de investimentos cresce (42,8 mil milhões em ações cotadas em julho de 2026), o lucro líquido vai ficar mais sensível aos mercados.

Perspetiva, não tendência garantida. O primeiro semestre de FY2027 (fevereiro a julho de 2026) somou 177,8 mil milhões de receita e 69,9 mil milhões de free cash flow, e a empresa previu 108 mil milhões para o terceiro trimestre (agosto a outubro de 2026) (comunicado Q2 FY2027). Isto é uma previsão da gestão, não um resultado.

O balanço está a mudar. Durante anos a NVIDIA teve pouca dívida e muita caixa. Em julho de 2026 a dívida tinha subido para cerca de 33 mil milhões (contra 8,5 no fim de FY2026), ao mesmo tempo que crescia a carteira de participações em clientes e parceiros. A posição continua confortável, mas a empresa passou a usar o balanço de forma mais ativa.

Retorno sobre o capital. Não apresento um ROIC preciso porque o capital investido da NVIDIA é dominado por caixa e participações financeiras, o que torna o cálculo muito sensível à metodologia. Qualitativamente, o negócio operacional exige muito pouco capital físico (ativos fixos e inventário são pequenos face ao lucro), pelo que o retorno sobre o capital operacional é excecionalmente alto por qualquer medida razoável.

Comparações dificultadas. A Mellanox entra nas contas a partir de abril de 2020 (FY2021). A segmentação mudou em FY2027 (de cinco mercados para Data Center e Edge Computing), o que impede comparar diretamente jogos ou automóvel com anos anteriores. A partir de FY2027 as métricas não-GAAP passaram a incluir o custo das remunerações em ações.

11. O setor e o contexto externo

A NVIDIA esteve bem posicionada para três grandes transformações externas que não controlou: o abrandamento da Lei de Moore, a explosão dos dados e da IA, e o maior ciclo de investimento em infraestrutura tecnológica da história. Distinguir o que foi mérito do que foi vento a favor é essencial para avaliar a durabilidade dos resultados.

Transformações tecnológicas

- **O fim do “almoço grátis” dos CPU.** Até meados dos anos 2000, os CPU ficavam mais rápidos a cada geração sem esforço dos programadores. Depois, os ganhos passaram a vir do paralelismo (mais núcleos), o que favoreceu arquiteturas paralelas como a GPU. Huang chama a isto o fim da Lei de Moore para os CPU e a ascensão da “computação acelerada”. Foi uma tese correta, mas a tendência é do setor, não uma criação da NVIDIA.
- **Dados e redes neuronais.** A disponibilidade de grandes conjuntos de dados (ImageNet, a internet inteira) e o avanço algorítmico (Transformers, 2017) tornaram as redes neuronais úteis. A NVIDIA não causou estas mudanças, mas estava preparada para servi-las.
- **Leis de escala.** Desde cerca de 2020, os laboratórios de IA observaram que modelos maiores, treinados com mais dados e mais computação, ficam previsivelmente melhores. Isto transformou a computação no principal fator de produção da IA. Mais recentemente, os modelos de raciocínio (que “pensam” antes de responder) e os agentes aumentaram a computação necessária na inferência, não apenas no treino.

O ciclo de investimento

O fator externo mais importante hoje é o investimento em centros de dados das grandes tecnológicas. Segundo a compilação do Financial Times citada pela Tom's Hardware, Amazon, Microsoft, Alphabet e Meta investiram cerca de 410 mil milhões de dólares em 2025 e planeavam cerca de 725 mil milhões em 2026 (Tom's Hardware). Uma parte grande desse dinheiro acaba na NVIDIA. Duas dessas empresas (Microsoft e Meta) estão neste portefólio, o que significa que o portefólio está, ao mesmo tempo, do lado de quem gasta e do lado de quem recebe.

A história dos ciclos de infraestrutura (caminhos de ferro no século XIX, fibra ótica em 1998–2001) mostra que períodos de investimento intenso tendem a terminar em excesso de capacidade, mesmo quando a tecnologia acaba por ser transformadora. Isto não prova que o ciclo da IA terminará assim, mas é a referência histórica relevante. A diferença citada pelos otimistas é que os principais compradores atuais financiam o investimento com lucros de negócios existentes, não com dívida, embora o recurso a dívida e a financiamento estruturado tenha aumentado em 2025–26.

Energia e infraestrutura física

Os centros de dados de IA são agora medidos em gigawatts. O acesso a ligações à rede elétrica, turbinas, transformadores e água de refrigeração tornou-se um limite real ao ritmo de construção nos EUA e na Europa. Isto tem dois efeitos opostos sobre a NVIDIA:

limita a quantidade de sistemas que os clientes conseguem instalar, mas favorece o fornecedor com melhor desempenho por watt.

Geopolítica

- **Controlo de exportações EUA–China.** Ver ponto de viragem 3.8. A política tem oscilado entre restrições e autorizações condicionadas a pagamentos ao Estado norte-americano (15% para o H20 em 2025, 25% para o H200 em 2026), e a China respondeu restringindo compras.
- **Taiwan.** Quase toda a produção avançada da NVIDIA é feita pela TSMC em Taiwan. Um bloqueio ou conflito teria efeitos imediatos e graves. A produção no Arizona está a começar mas não substitui Taiwan nesta década, sobretudo no empacotamento avançado.
- **IA soberana.** Governos (Médio Oriente, Japão, Coreia, Europa) passaram a financiar capacidade de computação nacional por razões estratégicas, abrindo uma nova categoria de clientes menos sensível ao retorno económico imediato.
- **Tarifas.** As políticas comerciais dos EUA em 2025–26 criaram incerteza sobre custos de importação de componentes e sistemas, e incentivaram anúncios de produção nos EUA.

Regulação e concorrência

A NVIDIA está sob escrutínio de autoridades de concorrência em várias jurisdições. A autoridade de concorrência chinesa abriu uma investigação em dezembro de 2024 e concluiu preliminarmente, em setembro de 2025, que a NVIDIA violou condições impostas na aprovação da compra da Mellanox, e as autoridades norte-americanas e europeias examinaram práticas comerciais e operações como a Run:ai. O risco regulatório é descrito com mais detalhe na secção 12.

Taxas de juro e mercados financeiros

As taxas de juro afetam a NVIDIA sobretudo de forma indireta: os seus clientes mais pequenos (nuvens especializadas, laboratórios) financiam-se com dívida e capital de risco, e o custo desse capital determina quanto podem gastar. Uma subida de taxas ou uma correção nas avaliações das empresas de IA reduziria o financiamento disponível para comprar GPU.

Mérito ou vento a favor?

Fator	Natureza	Avaliação
A IA moderna precisar de cálculo paralelo	Externo	Sorte estrutural: a GPU já existia por causa dos jogos
O CUDA estar pronto e difundido quando a IA surgiu	Interno	Mérito, com elementos de sorte quanto à aplicação que surgiu
A explosão do ChatGPT em 2022–23	Externo	Timing favorável que ninguém previu com precisão
Ter a H100, a rede e a capacidade reservada nesse momento	Interno	Mérito de execução
O investimento de 700 mil milhões anuais das grandes tecnológicas	Externo	Condição de mercado que pode mudar
Margens brutas de 75%	Misto	Parte vantagem estrutural, parte escassez temporária
Perda da China	Externo	Vento contra, compensado pelo crescimento noutros mercados

12. Os riscos, as fragilidades e os possíveis pontos de rutura

O maior risco da NVIDIA não é perder a liderança tecnológica; é que a procura pelo produto em que lidera abrande ou se torne mais sensível ao preço. Numa empresa com margens operacionais de 60% e quase toda a receita num só segmento, mesmo uma desaceleração moderada teria efeitos grandes no lucro.

1. Um abrandamento do ciclo de investimento em IA

Mecanismo. A receita da NVIDIA é o investimento dos seus clientes. Se as grandes tecnológicas concluírem que o retorno do investimento em IA é insuficiente, ou se os laboratórios de IA tiverem dificuldade em financiar-se, as encomendas caem. Como a NVIDIA tem compromissos de compra com fornecedores e custos de I&D quase fixos, a queda do lucro seria mais do que proporcional. O precedente é FY2023: receita estagnada e lucro líquido a cair 55%.

Sinais de alerta. Revisões em baixa das previsões de investimento das grandes tecnológicas; aumento de inventário e de pagamentos antecipados na NVIDIA sem crescimento correspondente da receita; descontos ou prazos de entrega mais curtos;

queda do preço de aluguer de GPU na nuvem; dificuldades de financiamento das nuvens especializadas.

2. Concentração de clientes

Mecanismo. Dois clientes diretos valeram 36% da receita em FY2026, e por trás deles estão poucas empresas finais. Cada uma tem poder negocial e incentivo para reduzir a dependência. Se uma delas transferir uma parte relevante das compras para chips próprios, o efeito na receita é imediato.

Sinais de alerta. Grandes nuvens a anunciar que a maior parte de nova capacidade interna será com chips próprios; contratos de grande dimensão de laboratórios com TPU, Trainium ou AMD (já existem: Anthropic com a Google e a Amazon, OpenAI com a AMD e a Broadcom).

3. Chips próprios dos clientes (ASIC)

Mecanismo. Para cargas de trabalho previsíveis e enormes (servir um modelo popular a milhares de milhões de utilizadores), um chip desenhado para essa tarefa pode custar menos por resultado do que uma GPU de uso geral, sobretudo porque o cliente não paga a margem da NVIDIA. Quanto mais a IA passar do treino para a inferência padronizada, maior este risco.

Sinais de alerta. Crescimento da receita de IA personalizada da Broadcom e da Marvell mais rápido do que a receita de centros de dados da NVIDIA; descida da quota da categoria Hyperscale na receita da NVIDIA.

4. Erosão do fosso de software

Mecanismo. Se o PyTorch, o JAX e compiladores como o Triton tornarem o hardware intermutável, e se os modelos de IA ajudarem a reescrever código para outras plataformas, os custos de mudança diminuem.

Sinais de alerta. Novos modelos de fronteira treinados e servidos sem NVIDIA; ferramentas abertas que correm igualmente bem em AMD; anúncios de grandes empresas a migrar cargas de inferência.

5. Compressão de margens

Mecanismo. Margens de 75% atraem concorrência. Além disso, a memória HBM e os componentes de sistema têm preços crescentes, e vender bastidores completos inclui componentes de margem menor. A NVIDIA pode continuar a crescer em receita e ver a margem descer.

Sinais de alerta. Margem bruta abaixo de 70% sem encargos extraordinários; previsões de margem em descida nas novas gerações.

6. Dependência da TSMC e de Taiwan

Mecanismo. Um único fornecedor, localizado numa zona de risco geopolítico, produz praticamente todos os chips avançados da NVIDIA. Não há alternativa equivalente a curto prazo: a Samsung e a Intel estão atrás nos processos mais avançados.

Sinais de alerta. Tensão militar no estreito de Taiwan; atrasos na produção da TSMC; restrições de capacidade em empacotamento avançado.

7. Geopolítica e regulação

Mecanismo. Além da China (já praticamente perdida para chips de centro de dados), os EUA podem alargar restrições a outros países (as regras de "difusão de IA" propostas em janeiro de 2025 e depois revogadas mostram que isso é possível). As autoridades de concorrência podem limitar práticas como a venda conjunta de GPU e rede, a afetação preferencial de produto, ou operações do tipo Groq. A China pode retaliar contra a NVIDIA em processos de concorrência.

Sinais de alerta. Processos formais de concorrência nos EUA ou na UE; novas regras de exportação; multas na China.

8. "Financiamento circular" e qualidade da procura

Mecanismo. A NVIDIA investe em clientes (OpenAI, Anthropic, nuvens especializadas) e apoia plataformas de financiamento de centros de dados. Se esses clientes dependem desse capital para comprar GPU, parte da procura é sustentada pelo próprio balanço da NVIDIA ou por capital que pode desaparecer numa correção. Em caso de crise, a NVIDIA perderia receita e registaria perdas nos investimentos ao mesmo tempo.

Sinais de alerta. Crescimento das participações e de garantias dadas pela NVIDIA; dificuldades financeiras de nuvens especializadas; quedas de avaliação de laboratórios de IA em rondas de financiamento.

9. Dependência de Jensen Huang

Mecanismo. A seleção de apostas, as relações com os grandes clientes e governos, e a cultura dependem fortemente de uma pessoa com 63 anos, sem sucessor publicamente designado. Uma saída inesperada criaria incerteza estratégica, ainda que a equipa executiva seja estável e experiente.

Sinais de alerta. Ausência de um plano de sucessão visível; saídas de executivos de topo de longa data.

10. Execução da cadência anual

Mecanismo. Uma arquitetura nova por ano, com bastidores cada vez mais complexos (energia, refrigeração líquida, memória), aumenta a probabilidade de atrasos e problemas de fiabilidade. Um atraso relevante dá aos concorrentes uma janela.

Sinais de alerta. Problemas de rendimento de produção, atrasos nas entregas do Rubin e Rubin Ultra, queixas públicas de clientes sobre fiabilidade.

11. Valorização e expectativas

Não é um risco do negócio, mas é um risco para o acionista. A queda de cerca de 17% num só dia após o lançamento do modelo chinês DeepSeek R1, em janeiro de 2025 (perda de cerca de 590 mil milhões de dólares de capitalização, a maior da história da bolsa norte-americana segundo a Bloomberg), mostrou como o preço da ação é sensível a qualquer sinal de que a IA possa precisar de menos computação. O receio não se confirmou nos resultados seguintes, mas o episódio ilustra a fragilidade das expectativas.

Os sinais mais importantes de que a vantagem está a enfraquecer

Se tivesse de escolher três: (1) margem bruta persistentemente abaixo de 70% sem explicação extraordinária; (2) crescimento dos chips personalizados das grandes nuvens mais rápido do que o dos centros de dados da NVIDIA durante vários trimestres; (3) um laboratório de fronteira a treinar e servir os seus melhores modelos inteiramente fora da NVIDIA, com resultados competitivos. Este último já acontece parcialmente (a Google com a TPU), o que torna o acompanhamento ainda mais importante.

13. A empresa hoje e o seu futuro estratégico

A NVIDIA está numa fase de hipercrescimento maduro: já é a maior empresa de semicondutores do mundo, continua a crescer acima de 100% ao ano em receita trimestral, e o desafio deixou de ser conquistar mercado para passar a ser defender a posição enquanto o mercado se transforma.

Onde está hoje (factos observados)

- Receita do 2.º trimestre de FY2027 (maio–julho de 2026): 96,2 mil milhões (+106% em termos homólogos); previsão para o 3.º trimestre: 108 mil milhões.
- Margem bruta de 75%, de volta ao máximo histórico após o arranque do Blackwell.
- Vera Rubin em produção, com bastidores em funcionamento em várias nuvens; acelerador Groq 3 LPX em produção; switches Spectrum-6 em entrega (comunicado Q2 FY2027).

- Clientes: segundo Huang, cerca de 60% do negócio vem dos cinco maiores fornecedores de nuvem (DatacenterDynamics).

O que a gestão afirma (declarações, não factos)

- Na GTC de março de 2026, Huang disse ver pelo menos um bilião de dólares em encomendas de Blackwell e Rubin (incluindo a rede associada) até ao fim de 2027. A diretora financeira esclareceu que o número não inclui produtos novos como a Groq ou CPU vendidos isoladamente. Analistas sublinharam que se trata de um pipeline de encomendas, não de receita garantida.
- A NVIDIA anuncia que o Rubin reduz o custo por token de inferência até dez vezes face ao Blackwell.
- Huang descreve a IA como uma nova revolução industrial em que os centros de dados se tornam "fábricas de IA" que produzem tokens, e argumenta que a procura de computação vai crescer com a passagem para agentes e IA física (robôs, veículos).

Motores de crescimento

1. **Inferência e agentes.** À medida que os modelos são usados por mais pessoas e empresas, e que os agentes executam tarefas longas, a computação para servir modelos cresce mais do que a de treino. É também o terreno mais contestado (ASIC, Groq, AMD).
2. **Clientes fora das grandes nuvens.** IA soberana, nuvens especializadas e empresas (a categoria ACIE, já cerca de metade dos centros de dados).
3. **Rede.** O segmento de crescimento mais rápido em 2026, à medida que os clusters crescem para centenas de milhares de GPU.
4. **CPU.** O Vera passou a ser vendido também isoladamente, por exemplo à SpaceXAI, entrando num mercado dominado por Intel e AMD.
5. **IA física: robótica e automóvel.** Promessa de longo prazo (Cosmos, Isaac, DRIVE Hyperion para robô-táxis). Até agora, receita pequena.
6. **Edge Computing.** PC com IA (RTX Spark com a Microsoft), estações de trabalho, consolas, estações de rede móvel com IA (parceria com a Nokia).

Onde investe dinheiro, talento e recursos

I&D numa cadência anual (Rubin Ultra em 2027, Feynman depois); compromissos de capacidade com TSMC e fornecedores de memória; recompras de ações (cerca de 26 mil milhões no 2.º trimestre); e, cada vez mais, participações em clientes e parceiros e plataformas de financiamento de centros de dados.

Desafios e competências a desenvolver

- Competir em custo na inferência sem destruir a própria margem.
- Manter o software como padrão num mundo de compiladores e frameworks agnósticos.
- Gerir uma cadeia de abastecimento cada vez mais complexa (energia, refrigeração, memória, ótica).
- Diversificar clientes para reduzir a dependência dos cinco maiores.
- Preparar a sucessão e uma organização menos dependente de uma pessoa.

Acontecimentos que podem alterar a trajetória

Os planos de investimento das grandes tecnológicas para 2027; os resultados financeiros da OpenAI e da Anthropic (a sua capacidade de gerar receita justifica a computação comprada?); uma eventual entrada em bolsa da OpenAI; o desempenho real do Rubin face à TPU e à AMD MI400; decisões regulatórias nos EUA, UE e China; a situação no estreito de Taiwan.

Três cenários para os próximos cinco a dez anos

Cenários qualitativos, baseados em inferência analítica. Não são previsões.

Cenário favorável. A IA torna-se uma tecnologia de uso geral integrada em quase todo o software e em sistemas físicos (robôs, veículos, fábricas). A procura de computação continua a crescer mais depressa do que a eficiência dos chips, porque cada redução de custo gera mais uso (o chamado paradoxo de Jevons). A NVIDIA mantém a liderança em treino e na maior parte da inferência graças à integração de sistema e ao software, e torna-se também um fornecedor relevante de CPU, rede e computação para robótica. As margens descem um pouco, mas o volume compensa. A empresa transforma-se numa espécie de “Intel + Cisco + Microsoft” da era da IA.

Cenário central. A IA continua a crescer, mas o investimento em infraestrutura abranda após o pico de 2026–28, com pelo menos um período de digestão em que os clientes absorvem a capacidade instalada. Os chips personalizados das grandes nuvens ganham uma fatia relevante da inferência interna (por exemplo, um terço a metade dessas cargas), e a AMD torna-se uma segunda fonte sólida. A NVIDIA continua líder, com quota menor do que hoje, margem bruta na casa dos 60–70% e crescimento mais volátil: anos fortes alternados com anos de estagnação, como na sua história anterior. Continua a ser um negócio excelente, mas mais cíclico do que o período 2023–26 sugere.

Cenário desfavorável. O retorno económico da IA fica aquém das expectativas durante vários anos; laboratórios e nuvens especializadas com dívida enfrentam dificuldades; as grandes tecnológicas cortam investimento de forma abrupta. Ao mesmo tempo, a

inferência migra em grande parte para ASIC e o fosso de software erode. A receita da NVIDIA cai de forma significativa durante dois ou três anos, a margem desce com a concorrência de preços, e as participações em clientes perdem valor. Um choque geopolítico em Taiwan seria uma variante ainda mais grave deste cenário, porque afetaria a capacidade de produção e não apenas a procura. A empresa sobreviveria com facilidade (tem caixa e tecnologia), mas o lucro de 2026 poderia demorar muitos anos a ser recuperado.

14. O que um investidor deve acompanhar

Oito indicadores chegam para seguir a saúde do negócio trimestre a trimestre sem reagir a cada notícia. Quase todos estão nos comunicados trimestrais e nos relatórios 10-Q/10-K, disponíveis em investor.nvidia.com e na SEC.

Indicador	O que mede	Porque importa	Sinal positivo	Sinal de alerta	Onde acompanhar
Receita de Data Center e previsão do trimestre seguinte	A procura pelo produto principal	É 90% do negócio; a previsão mostra a visibilidade da gestão	Crescimento sequencial positivo e previsões cumpridas ou superadas	Previsão abaixo do trimestre anterior; crescimento sequencial a desacelerar vários trimestres seguidos	Comunicado trimestral e teleconferência
Hyperscale versus ACIE	Diversificação de clientes	Mede a dependência dos cinco maiores	ACIE a crescer igual ou mais rápido	ACIE a estagnar enquanto Hyperscale concentra o crescimento	Comunicado trimestral e apresentação da diretora financeira
Margem bruta	Poder de preço e custo de produção	O melhor sinal da força competitiva	Estável em torno de 73–75% através das transições de geração	Abaixo de 70% sem encargo extraordinário; previsões em descida	Comunicado trimestral
Inventário, pagamentos antecipados e compromissos de compra	O risco assumido face a fornecedores	Antecipa excesso de oferta	Crescem em linha com a receita	Crescem muito mais depressa do que a receita	Balanço e notas do 10-Q

Indicador	O que mede	Porque importa	Sinal positivo	Sinal de alerta	Onde acompanhar
Fluxo de caixa operacional versus lucro líquido	Qualidade do lucro	Mostra se o lucro se converte em dinheiro	Conversão próxima de 80–100% em média anual	Conversão baixa durante vários trimestres (ganhos não realizados, clientes a pagar mais tarde)	Demonstração de fluxos de caixa
Concentração de clientes	Peso dos maiores clientes diretos	Risco de dependência	Peso dos dois maiores a descer	Um cliente acima de 25%	Nota de concentração no 10-Q/10-K
Participações, garantias e dívida	Uso do balanço para financiar o ecossistema	Mede o risco de "financiamento circular"	Participações estáveis em proporção à receita	Crescimento rápido de participações em clientes, garantias ou dívida	Balanço, notas sobre investimentos e compromissos
Receita de chips personalizados da Broadcom e da Marvell	Avanço dos ASIC nas grandes nuvens	Principal ameaça estrutural à quota	Cresce mais devagar do que o Data Center da NVIDIA	Cresce mais depressa durante vários trimestres	Resultados da Broadcom (outro dossier deste documento) e da Marvell

Indicadores qualitativos complementares

- **Planos de investimento das grandes tecnológicas** (Microsoft, Meta, Alphabet, Amazon, Oracle), anunciados nos resultados trimestrais. São a melhor previsão da receita da NVIDIA para os trimestres seguintes.
- **Preços de aluguer de GPU na nuvem.** Uma descida acentuada indica excesso de oferta.
- **Calendário de produtos.** Cumprimento das datas do Rubin Ultra (2027) e da arquitetura Feynman.
- **Adoção de alternativas.** Modelos de fronteira treinados ou servidos sem NVIDIA; maturidade do ROCm da AMD.
- **Regulação e exportações.** Regras do Departamento de Comércio dos EUA, decisões de autoridades de concorrência.

Próximos acontecimentos relevantes

- Resultados das grandes tecnológicas do 3.º trimestre de 2026 (final de outubro de 2026), com planos de investimento para 2027.

- Resultados do 3.º trimestre do ano fiscal de 2027 da NVIDIA (agosto–outubro de 2026), esperados para o final de novembro de 2026.
- Resultados anuais do ano fiscal de 2027 e relatório 10-K (final de fevereiro de 2027), com a nova nota de concentração de clientes.
- Conferência GTC (março de 2027): roteiro de produtos e atualização do volume de encomendas.
- Eventual entrada em bolsa da OpenAI e rondas de financiamento dos laboratórios de IA.

15. As lições empresariais mais importantes

1. **Uma plataforma vale mais do que um produto, mas leva anos a pagar-se.** O CUDA (2006) custou margem durante quase uma década antes de se tornar o ativo mais valioso da empresa. A NVIDIA compreendeu antes dos concorrentes que o hardware sem software próprio é facilmente substituível. A lição para o investidor: as melhores vantagens competitivas costumam ser construídas em períodos em que a empresa parece estar a desperdiçar dinheiro.
2. **Usar um mercado para financiar o seguinte.** Os jogos pagaram a GPU, a GPU pagou o CUDA, o CUDA abriu a IA. A NVIDIA nunca precisou de convencer investidores a financiar a IA desde zero; foi o negócio existente que pagou a opção. Empresas que conseguem esta sequência têm uma vantagem enorme sobre startups que apostam tudo num mercado que ainda não existe.
3. **Seguir o padrão quando ele existe; criar o padrão quando ele não existe.** O NV1 falhou por combater o DirectX. O CUDA venceu porque não havia padrão para computação paralela geral. Saber distinguir as duas situações foi decisivo.
4. **Reconhecer cedo um sinal vindo de fora.** A NVIDIA não inventou o deep learning, mas reorganizou-se em torno dele poucos anos depois da AlexNet (2012), quando o mercado era ainda académico. Muitas empresas têm a tecnologia certa e não reconhecem a aplicação decisiva quando ela aparece.
5. **Comprar o futuro estrangulamento.** A Mellanox (2019) foi comprada quando a rede ainda não era vista como o limite da IA. A melhor aquisição da empresa não foi a maior nem a mais vistosa, mas a que antecipou onde estaria o problema seguinte.
6. **Sair depressa do que não funciona.** Telemóveis, Icera e chipsets foram abandonados sem tentativas prolongadas de ressuscitação. O erro evitável não foi entrar (era uma aposta razoável em 2008) mas permanecer cerca de seis anos num mercado onde a integração do modem pela Qualcomm tornava a posição insustentável desde cedo.
7. **Manter o investimento durante as recessões.** Em 2022, com a receita estagnada e a ação a cair dois terços, a NVIDIA manteve a H100 e a capacidade de produção. Quando o ChatGPT chegou, era a única preparada. Quem corta no fundo do ciclo não captura a

recuperação.

8. **A velocidade como estratégia.** Do ciclo de seis meses nos anos 90 à cadência anual de arquiteturas de centro de dados desde 2024, a NVIDIA usou a velocidade para obrigar os concorrentes a acertar num alvo em movimento. A contrapartida é o risco de execução, como mostrou o atraso do Blackwell.
9. **Os reguladores definem os limites do crescimento por aquisição.** O fracasso da Arm (2022) mostrou que, a partir de certa dimensão, comprar peças neutras do ecossistema deixa de ser possível. A resposta da NVIDIA (licenças em vez de compras, como na Groq) poderá, por sua vez, atrair escrutínio.
10. **Sorte e preparação não se excluem.** A generosidade da Sega, a AlexNet ter usado placas GeForce, o ChatGPT ter surgido quando a H100 estava pronta: houve sorte em momentos decisivos. Mas a sorte só foi aproveitada porque a empresa tinha o produto, o software e a organização prontos. O investidor deve resistir à narrativa de inevitabilidade e perguntar o que acontece se a próxima vaga de sorte não vier.

16. Síntese final

1. **O que é verdadeiramente esta empresa?** Uma empresa de plataforma de computação que desenha chips, sistemas, redes e software para IA e gráficos, e subcontrata toda a produção. Mais do que uma fabricante de chips, é hoje a arquiteta dos centros de dados de IA.
2. **Como ganha dinheiro?** Vendendo hardware de centro de dados (cerca de 92% da receita em meados de 2026) a preços que refletem o valor para o cliente e não o custo, o que gera margens brutas de cerca de 75%. O software é sobretudo gratuito e serve para prender o cliente ao hardware.
3. **Porque é que os clientes precisam dela?** Porque oferece o maior desempenho por watt e por dólar no conjunto do sistema, com o software mais maduro e entrega à escala, numa altura em que a capacidade de computação determina quanto os clientes conseguem faturar com IA.
4. **Qual foi a decisão mais importante da sua história?** O CUDA em 2006, e sobretudo a decisão de o colocar em todas as GPU e de o manter durante anos sem retorno.
5. **Quem mais contribuiu para a sua transformação?** Jensen Huang, como estratega e líder durante 33 anos. Mas o CUDA dependeu de Ian Buck, John Nickolls e David Kirk; a ponte para a IA de Bill Dally e Bryan Catanzaro, e de académicos externos como Hinton, Krizhevsky e Sutskever; e a escala da TSMC e da equipa de operações.
6. **Qual é a sua principal vantagem competitiva?** A combinação de três camadas difíceis de replicar em simultâneo: ecossistema de software (CUDA), integração de sistema completo (GPU, CPU, rede, bastidor) e escala de I&D e de cadeia de abastecimento.

7. **Qual é a sua maior fragilidade?** A dependência de um ciclo de investimento concentrado em poucos clientes muito poderosos, que são também os que têm mais incentivos e capacidade para desenvolver alternativas.
8. **O que poderá determinar o seu sucesso nos próximos dez anos?** Se a procura de computação para inferência e IA física continuar a crescer mais depressa do que a eficiência, e se a NVIDIA conseguir manter a liderança na inferência face a chips personalizados.
9. **O que poderia comprometer seriamente o seu futuro?** Uma correção prolongada do investimento em IA combinada com a migração da inferência para ASIC; ou um choque geopolítico em Taiwan.
10. **Qual é a lição mais importante?** Que as posições dominantes nascem muitas vezes de apostas que parecem más durante anos, financiadas por um negócio existente, e que a sorte só favorece quem está preparado. E, simetricamente, que nenhuma posição dominante numa indústria de ciclos curtos está garantida: a própria NVIDIA ganhou o mercado gráfico a uma 3dfx que parecia imbatível.

Cronologia

Data	Acontecimento	Porque importa
Abril de 1993	Fundação por Jensen Huang, Chris Malachowsky e Curtis Priem	Aposta em computação acelerada com os jogos 3D como primeiro mercado
1995	Lançamento do NV1	Fracasso por incompatibilidade com o DirectX
1995–96	Investimento de 5 milhões da Sega	Dá à empresa os meses de vida necessários
1997	RIVA 128	Salva a empresa; nasce a cultura de velocidade
Janeiro de 1999	Entrada em bolsa (Nasdaq)	Capital e visibilidade
1999	GeForce 256, “a primeira GPU”	A GPU passa a ser um processador
Dezembro de 2000	Compra dos ativos da 3dfx	Consolidação da liderança nos jogos
Novembro de 2006	CUDA e arquitetura G80	A decisão mais importante da história da empresa

Data	Acontecimento	Porque importa
2012	AlexNet treinada em GPU GeForce	A IA descobre a GPU
2016	DGX-1; primeiro sistema entregue à OpenAI	Primeiro produto dedicado à IA
Abril de 2020	Conclusão da compra da Mellanox	A NVIDIA passa a vender a rede e o sistema
Fevereiro de 2022	Abandono da compra da Arm	Limite regulatório ao crescimento por aquisição
Novembro de 2022 – maio de 2023	ChatGPT e previsão de 11 mil milhões	Início da explosão da IA generativa
2024–2025	Blackwell e GB200 NVL72; cadência anual	Venda de “fábricas de IA” completas
Abril de 2025 – janeiro de 2026	Restrições ao H20 e bloqueio chinês ao H200	Perda prática do mercado chinês de centros de dados
Dezembro de 2025 – 2026	Acordo com a Groq; investimento de 30 mil milhões na OpenAI	A NVIDIA passa a financiar e absorver o ecossistema
2026	Vera Rubin em produção; nova segmentação (Data Center e Edge Computing)	Receita trimestral perto de 100 mil milhões

Fontes do dossier NVIDIA

Documentos da empresa e regulatórios

- Comunicado de resultados do 4.º trimestre e ano fiscal de 2026 (8-K, SEC)
- Relatório anual 10-K do ano fiscal de 2026 (SEC)
- Comunicado de resultados do 2.º trimestre do ano fiscal de 2027
- Comunicado de resultados do ano fiscal de 2021
- Comunicado de resultados do ano fiscal de 2019
- Cronologia oficial da NVIDIA
- Discurso de Jensen Huang na Universidade Nacional de Taiwan, 2023 (blog NVIDIA)
- Arquivo de resultados trimestrais (relações com investidores)

Imprensa e análise

- Global Data Center Hub — nova segmentação e 1.º trimestre do ano fiscal de 2027
- DatacenterDynamics — investimento de 30 mil milhões na OpenAI
- DatacenterDynamics — encomendas de um bilião de dólares até 2027
- Constellation Research — natureza do acordo com a Groq
- TechSpot — acordo com a Groq
- Tom's Hardware — falha de desenho do Blackwell
- Tom's Hardware — investimento das grandes tecnológicas em 2026
- Bloomberg — queda após o DeepSeek
- BusinessDay/Reuters — bloqueio chinês ao H200
- Bloomberg Tax — primeiras vendas de H200 à China
- The Next Web — o investimento da Sega
- StockAnalysis — séries financeiras anuais FY2022–26

Livros e entrevistas extensas (para aprofundar)

- Tae Kim, *The Nvidia Way* (2024) — história da empresa com base em entrevistas a executivos e antigos trabalhadores.
- Stephen Witt, *The Thinking Machine* (2025) — biografia de Jensen Huang e da viragem para a IA.
- Podcast *Acquired*, episódios sobre a NVIDIA (2022) e entrevista com Jensen Huang (2023).

Alguns detalhes históricos (montante do financiamento inicial, unidades vendidas do RIVA 128, preço da 3dfx, PortalPlayer e Icera, encargo de 2008) vêm de relatos amplamente citados e dos livros acima, e não foram verificados nesta investigação contra documentos primários; devem ser lidos como aproximados.